가천 X 세종

연합 학술제

연구 파트 보고서

감성 및 거래 특성을 반영한 시계열 딥러닝 앙상블을 통한 KOSPI200 지수 예측 연구

팀 이름 : 박박박사

제출 일자 2025.08.22

팀장	박재현	팀원	박종원

초록

본 연구는 한국어 뉴스 감성과 거래 특성을 결합하여 KOSPI200의 T+1 종가를 예측한다. 2022-01-27~2024-12-30 기간의 KRX 가격·거래량과 **[1]** 빅카인즈 뉴스를 결합하였다. 감성은 KoBERT 이진 분류로 기사별 긍정·부정 확률을 산출하고, 1군방송사(5개), 2군경제지(12개)에 3점과 1점이라는 값을 가중치로 적용해 기업별 일자 단위로 집계했다. 입력은 10개 핵심 종목의 [pos, neg, emotion, calculate(pos−neg), trading, change] 6개 피처를 21일 이동창 윈도우로 구성(총60차원)하였다. 시계열 분할은 비율 고정(Train 71%, Val 15.1%, Test 13.9%)이며, 정규화는 Train 기준 MinMax를 적용, 공유하였다. 또한, 본 연구에서는 단순 주가 데이터망을 활용한 예측을 초기 모델로 삼아 거래량, 변동성·감정 분석 결과와 같은 유의미한 피처들을 점진적으로 통합하였다. 또한, 단일 모델(LSTM)뿐만 아니라 CNN, GRU 등의 구조를 결합한 Hybrid ensemble을 적용하여 예측 성능을 심화 학 습 방식으로 향상시켰다. 본 연구는 매체 군 가중 집계와 Hybrid ensemble의 유효성을 한국 시장 데이터에서 실증하며, 장마감 컷오프 미 명시 등 한계를 논의하고 수익률 타깃, 백테스팅, 통계검정을 향후과제로 제안한다.

1. 서론

금융시장에서 주가 예측은 투자 의사결정, 기업 가치 평가, 리스크 관리 등 다양한 영역에서 핵심적인 역할을 한다. 그러나 주가는 거시경제 지표, 기업 실적, 투자 심리, 외부 충격 등 복합적인 요인에 의해 결정되므로 정확한 예측은 여전히 난제로 남아 있다. 최근 연구에서는 비정형 데이터, 특히 뉴스 텍스트를 활용하여 시장 참여자의 심리를 정량화 하는 시도가 활발히 이루어지고 있으며, 이는 전통적인 가격·거래량 기반 예측 모델의 한계를 보완할 수 있는 방안으로 주목받고 있다. 이러한 배경에서 한국어 뉴스 감성과 거래 특성을 결합한 다변량 시계열 입력 구조를 제안하고, Hybrid ensemble을 통한 LSTM 모델을 활용하여 KOSPI200의 다음날 종가 수준을 예측하는 방법론을 개발하였다. 코로나19 이후 시장의 안정화를 고려하여 설정한 기간인 LG에너지솔루션 상장일(2022년 1월 27일)부터 2024년 12월 30일까지의 KRX 가격 및 거래량과 빅카인즈 뉴스 데이터를 연구 데이터로 사용했다. 본 연구의 주요 기여는 다음과 같다. 첫째, 국내 언론 생태계를 반영하여 방송사(1군)와 경제지(2군)를 구분한 이원 가중 감성 집계식을 제안한다. 둘째, 기업별 감성 지표와 거래 특성을 결합하여 다변량 시계열 입력 구조를 설계한다. 셋째, 단일 모델의 불안정성을 완화하기 위해 Hybrid ensemble을 적용하여 일반화 성능을 향상시켰다. 한국어 뉴스 데이터와 KOSPI20 0 환경에 최적화된 입력 설계와 집계 방식을 통해 기존 연구와 차별성을 가진다. 전반적인 데이터는 Google에 있는 Colab에서 진행하였고, 시간이 오래 걸리는 학습 같은 코드는 Micro soft에 Visu al Studio Code에서 진행하였다.

2. 관련연구 (Related Work)

주가 예측 연구는 전통적으로 통계적 기법을 중심으로 발전해왔으나, 최근에는 딥러닝 기반 모델과 자연어 처리 기술의 결합을 통한 접근이 활발하게 이루어지고 있다.

첫째, **[2]** '*KOSPI Index Prediction using Topic Modeling and LSTM*' 에서는 뉴스 기사를 형태소 분석한 후 LDA 기반 토픽 모델링을 적용하고, 이를 LSTM 모델과 결합하여 KOSPI 지수를 예측하였다.
둘째, **[3]** '*Combining News Sentiment and Technical Analysis to Predict Stock Trend Reversal*' 에서는 뉴스·소셜미디어의 감성 분석과 기술적 지표를 결합하여 주가 반전 시점을 탐지하였다. 이는 감성과 기술적 분석을 통합한 다변량 접근이지만, 한국어 데이터와 KOSPI200 환경에 특화되지 않은 한계를 가진다.
셋째, **[4]** '*감정분석과 GRU 모델 기반의 주가지수 예측 및 분석*' 에서는 한국어 뉴스를 KoBERT 기반 감성 분석 후 GRU 모델에 적용하여 KOSPI200 내 에너지·화학 업종을 대상으로 예측을 수행하였다. 감성 분석을 활용한 점에서 본 연구와 유사하나, 거래 특성은 고려하지 않았고 적용 범위가 특정 업종에 국한되었다.
넷째, **[5]** '*Performance of Deep Learning in Prediction of Stock Market*'에서는 LSTM, CNN 등 딥러닝 모델들의 성능을 비교함으로써 주가 예측 가능성을 검증하였다. 특정 데이터셋보다는 모델의 구조적 성능 차이에 초점을 두었으며, 뉴스 감성이나 거래 특성과의 결 합은 다루지 않았다. 이상의 선행 연구들은 주로 뉴스 감성만 활용하거나, 특정 섹터 또는 주제에 한정하거나, 모델 성능 자체에 집중하는 경향을 보였다. 반면 본 연구는 방송, 경제지 이원 가중 집계식, 거래 특성 과 결합된 다변량 입력 설계, Hybrid ensemble LSTM을 통한 일반화 성능 개선을 통해 한국어 기반 KOSPI200 예측 연구에 새로운 기여를 제공한다.

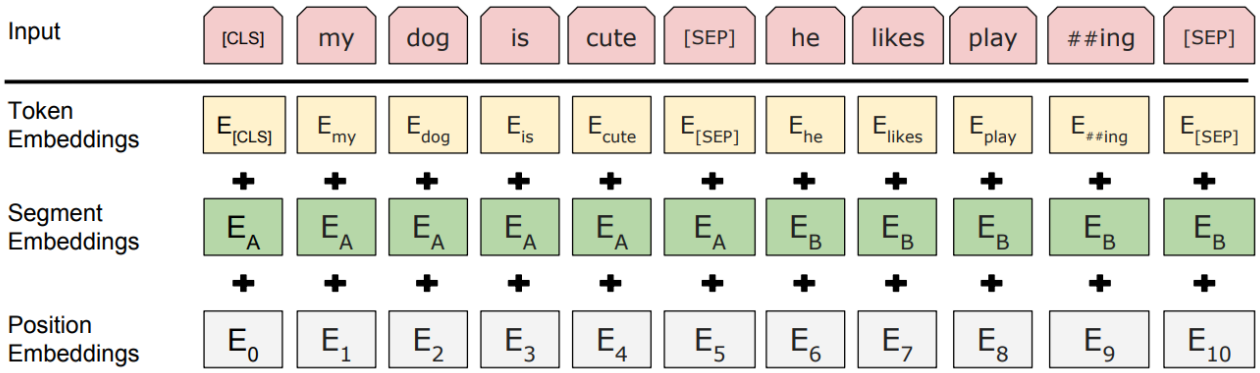
3. Methodology & Experiment

3.1 모델설명

본 연구는 크게 두 단계로 구성된다.
첫째. 뉴스 텍스트 감성 분석 단계에서 KoBERT를 활용해 기사 단위 긍정·부정 감성을 추출한다.
둘째. 시계열 예측 단계에서 감성 확률과 거래 특성(거래량·변동률)을 다변량 입력으로 활용하여 **[6]** LSTM, GRU, CNN-LSTM 및 Seed Ensemble 기반 예측을 수행한다.

3.1.1 감성 분석 모델: **[7]** KoBERT

학습에 사용할 모델 후보로 KoBART, KoBERT, KoGPT2, BERT base multilingual cased 총 4개가 있었지만, 사전 검증 결과 가장 성능이 우수한 KoBERT를 최종 선택하였다. KoBERT는 SKTBrain에서 개발한 한국어 특화 BERT 모델로, BERT(Bidirectional Encoder Representations from Transformers) 구조를 한국어 데이터에 맞게 재학습시킨 모델이다. Transformer 인코더 기반의 다층 Self-Attention을 통해 양방향 문맥 정보를 학습할 수 있으며, WordPiece 기반의 서브워드 토크나이저를 사용해 형태소 분석과 띄어쓰기 문제를 최소화할 수 있다. 또한, 사전 학습된 모델을 활용함으로써 상대적으로 작은 학습 데이터셋에서도 안정적인 감성 예측 성능을 확보할 수 있다.



<Figure 1>

텍스트 입력 데이터는 WordPiece 토크나이저를 통해 서브워드 단위로 분절되며, 임베딩 층에서 벡터 표현으로 변환된다. 이후 다층 Self-Attention을 거쳐 문맥 임베딩을 생성하며, 최종적으로 SoftMax 분류기를 통해 **[8]** 긍정(Positive), 부정(Negative) 확률을 산출한다. 본 연구에서는 문장 단위 감성 확률을 집계한 후, 방송사, 경제지 이원 가중 집계 방식(3: 1)을 적용하여 일별 감성 지표를 생성하였다. 이렇게 생성된 감성 확률 벡터는 후속 시계열 모델의 입력 피처로 사용되었다.

3.1.2 시계열 예측 모델

[6] LSTM은 RNN의 장기 의존성 문제를 해결하기 위해 고안된 구조로, 입력 게이트(Input Gate), 망각 게이트(Forget Gate), 출력 게이트(Output Gate)로 구성된다. 시점 t에서 입력(x_t), 은닉 상태(h_t), 셀 상태(c_t)는 다음과 같이 갱신된다.

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f), \quad i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i)$$

$$c_t = f_t \odot c_{t-1} + i_t \odot \tanh(W_c \cdot [h_{t-1}, x_t] + b_c), \quad h_t = o_t \odot \tanh(c_t)$$

<Figure 2>

각각 망각, 입력, 출력 게이트이며, ⊙ 는 원소별 곱(element-wise multiplication)을 의미한다.
본 연구에서는 LSTM이 금융 시계열의 장기 추세를 학습하는데 주력하였다.

[6] GRU는 LSTM의 단순화된 변형으로, 업데이트 게이트(Update Gate)와 리셋 게이트(Reset Gate)만으로 상태 전이를 제어한다. 이는 파라미터 수를 줄여 학습 효율성을 높이는 동시에 장단기 의존성을 모두 학습할 수 있다는 장점이 있다. 본 연구에서는 LSTM 대비 학습 효율성과 예측 성능을 비교하기 위한 대조군으로 GRU를 적용하였다.

[6] CNN-LSTM은 합성곱 신경망(CNN)과 LSTM을 결합한 하이브리드 구조이다. CNN은 입력 시계열에서 지역적 패턴(예: 단기 급등락)을 추출하고, LSTM은 장기 의존성을 학습한다. 이러한 구조는 단기 이벤트와 장기 추세가 동시에 반영되어야 하는 금융 시계열 분석에 적합하다. CNN-LSTM을 보조 실험 모델로 활용하여, 단기 충격이 반영되는 효과를 검증했다. Seed Ensemble은 동일한 모델 구조(LSTM)를 서로 다른 초기 Seed로 학습한 후, 예측 결과를 평균(soft voting)하는 기법이다. 이는 초기 파라미터 설정 차이에 따른 결과 변동을 줄이고, 분산을 감소시켜 일반화

성능을 개선하는 효과가 있다. 본 연구에서는 LSTM을 5회 학습하여 Seed Ensemble을 구성하였다. 그 후에 Hybrid ensemble을 통해서 결론을 도출하였다.

3-2 데이터 셋

3.2.1 비정형 데이터

본 연구에서 활용한 비정형 데이터는 2022년 1월 27일부터 2024년 12월 30일까지 한국언론진흥재단 빅카인즈를 통해 수집한 뉴스 기사이다. 수집 대상은 KOSPI200 지수에 있는 상위 10개 기업(현대차, KB금융, 기아, LG화학, LG에너지솔루션, 네이버, 포스코홀딩스, 삼성바이오로직스, 삼성전자, SK하이닉스)으로 한정하였다. 데이터 수집 기간은 최근의 경제 정세와 시장 상황을 반영하여 예측의 시의성을 확보하기 위함이다. 수집 과정에서는 언론사 가중치를 고려하여 1군(방송사 및 경제지) 과 2군(대한경제, 매일경제, 머니투데이, 메트로경제, 브릿지경제, 서울경제, 아시아경제, 아주경제, 이데일리, 이투데이, 파이낸셜뉴스, 한국경제, 헤럴드경제)으로 구분하였으며, 기사별 긍정, 부정 확률, 이진 감성(emotion), 파생 변수 (calculate)를 구축하였다. 또한 중복 기사 제거(title+date 기준)와 한국어 기사 필터링을 통해 데이터 품질을 확보하였다. 최종적으로 기사 제목, 본문, 날짜, 언론사 등의 필드를 확보하였다.

3.2.2 정형 데이터

정형 데이터는 KRX에서 제공하는 KOSPI200 지수의 종가 및 기업별 거래량이다. 수집 기간은 비정형 데이터와 동일하게 2022년 1월 27일부터 2024년 12월 30일까지 설정하여 뉴스와 거래 데이터를 동일한 시계열 축 위에서 정렬할 수 있도록 하였다. 거래 특성으로는 거래량(trading)과 변동률(change)을 주요 변수로 채택하였다. 휴일과 주말은 최근 영업일 데이터로 대체하여 결측치를 처리했다. 거래량은 원시 수치를 MinMaxScaler로 정규화하여 모델 입력에 활용하였다. 변동성은 단순 일간 수익률 변동 기준으로 계산하였다.

3.3.3 데이터 전처리 및 분석

본 연구에서는 비정형 데이터와 정형 데이터를 결합하기 위하여 다음과 같은 전처리 과정을 수행하였다. 기업별 피처 구성을 각 기업에 대해 pos, neg, emotion, calculate, trading, change 총 6개 피처를 생성하였다. MinMaxScaler를 적용하여 모든 입력 변수를 0~1 범위로 스케일링하였다. 이 과정에서 Train 데이터만 fit하고, Validation 및 Test 구간에는 동일 변환만 적용하여 데이터 누설을 방지하였다. 시계열 샘플 생성 기준을 21일 이동 윈도우(window)를 기반으로 시계열 샘플입력 시퀀스를 구성했으며, 목표값(y)은 KOSPI200 지수의 다음 거래일 종가로 설정했다. 전체 데이터는 Train 71%, Validation 15.1%, Test 13.9%로 분할하였으며, 시계열 순서를 보존한 상태에서 구간별로 분리하였다.

3.4 감정분석

본 연구에서는 금융 뉴스 데이터를 기반으로 KOSPI200 지수와 주요 기업 주가 변동성을 설명할

수 있는 감정 피처를 구축하였다. 이를 위해 빅카인즈 뉴스 데이터를 활용하여 2022년 1월 27일부터 2024년 12월 30일까지의 기간 동안 KOSPI200 상위 10개 기업 관련 뉴스를 수집하였다. 수집된 뉴스는 기업별로 날짜 단위로 정리하였으며, 기사별 텍스트에 대해 KoBERT 기반 감성분석 모델을 적용하였다. 최종 Test에서는 93% 정확도를 보여 사용에 적합하다고 판단하여 진행하였다.

3.5 계산식

본 연구는 최종적으로 Adam optimizer를 사용하였다. Adam은 적응적 학습률(adaptive learning rate)과 모멘텀(momentum) 조정이 결합된 최적화 기법으로, 그 계산식은 다음과 같다:

$$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t$$
$$v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2$$

<Figure 3>

$$\hat{m}_t = \frac{m_t}{1-\beta_1^t}$$
$$\hat{v}_t = \frac{v_t}{1-\beta_2^t}$$

<Figure 4>

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\hat{v}_t} + \epsilon} \hat{m}_t$$

<Figure 5>

초기 실험에서 SGD, RMSProp, Adagrad 등을 적용하였으나, 학습 속도 저하 및 수렴 불안정 문제로 인해 예측 성능이 현저히 낮게 나타났다. 특히 변동성이 큰 금융 시계열 데이터의 비정상성(non-stationarity)에도 Adam이 안정적으로 수렴하였고, 예측 지표에서도 일관적으로 우수한 결과를 보여 최종 optimizer로 Adam을 채택하였다.

4. 모델 연구 및 평가

4.1 모델 설명

본 연구에서는 KOSPI200 지수 예측을 위해 시계열 특성을 잘 반영할 수 있는 LSTM(Long Short-Term Memory) 모델과 GRU(Gated Recurrent Unit) 모델을 채택하였다. 두 모델 모두 순환 신경망(RNN)의 변형 구조로, 장기 의존성(Long-term dependency) 문제를 효과적으로 처리할 수 있으며 금융 시계열 데이터에 널리 활용된다. 모델의 입력은 기업별 주가와 거래량 등 정형 피처 2개와 뉴스 감성 분석을 통해 산출한 감정 피처 4개를 포함한 총 6개 피처를 사용하였다. 이를 상위 10개 기업에 대해 구성하여 최종적으로 60차원 입력 벡터를 생성하였다. 가격과 거래량 데이터는 거래일 기준으로 정렬하여 inner join 방식으로 뉴스 데이터와 결합하였다. 모델의 구조는 다음과 같다. 입력층은 기업별 60차원 시계열 피처를 입력으로 받으며, 은닉층은 LSTM 또는 GRU 은닉 유닛 50개를 두 층으로 구성하였다. 출력층은 KOSPI200 지수의 다음 거래일 종가 수준을 예측하도록 설계하였다. 손실함 수는 평균제곱오차(MSE)를 사용하였으며, 최적화 알고리즘은 Adam Optimizer(learning rate=0.00 1)를 적용하였다. 예측 이후에는 Scaler.inverse_transform을 통해 역정규화를 수행하여 실제 가격 수준으로 해석하였다. 모델은 과거 21일의 데이터를 입력 시퀀스로 사용하여 다음 1일의 종가 수 준을 예측하는 방식으로 설계되었다. Epoch는 100, batch size는 64로 학습을 진행하였으며, 학습 과정에서 Early Stopping을 도입하여 검증 성능이 개선되지 않는 시점에서 학습을 종료함으로써 과적합을 방지하였다.

4.2 모델 평가 지표

탐색적 데이터 분석 외엔 예측 성능 5개의 지표로 평가하였다. 평균 절대 오차(MAE)와 평균 제곱근 오차(RMSE)를 통해 오차의 크기를 평가한다. 특히, 평균 절대 백분율 오차(MAPE)는 데이터 규모에 관계없이 모델 성능을 비교하는 데 활용하며, 결정계수(R^2)는 회귀 모델의 설명력을 나타내는 지표로 사용된다. 또한, 분류 모델의 경우 F1 Score를 통해 정밀도와 재현율의 균형을 종합적으로 평가하였다.

$$\mathrm{MAE} = \frac{1}{m}\sum_{i=1}^{m}|X_i - Y_i|$$

<Figure 6>

$$\mathrm{RMSE} = \sqrt{\frac{1}{m}\sum_{i=1}^{m}(X_i - Y_i)^2}$$

<Figure 7>

$$\mathrm{MAPE} = \frac{1}{m}\sum_{i=1}^{m}\left|\frac{Y_i - X_i}{Y_i}\right|$$

<Figure 8>

$$F1 = \frac{2\,TP}{2\,TP + FP + FN}$$

<Figure 9>

$$\mathrm{R}^2 = 1 - \frac{\sum_{i=1}^{m}(X_i - Y_i)^2}{\sum_{i=1}^{m}(\bar{Y} - Y_i)^2}$$

<Figure 10>

4.3 모델 평가

4.3.1 모델 평가 전 학습 version확인

Pytorch와 다르게 version 제약이 있었기 때문에 환경을 만들고 진행하였다. Tensorflow: 2.10.0, Python : 3.10, CUDA Toolkit : 11.2, cuDNN: 8.1, NVDIA drive: 560.94, NumPy: 1.23.5 version을 사용하였다.

4.4 탐색적 데이터 분석

4.4.1 핵심적인 연구에 들어가기 전 데이터들에 관계 외에 학습 결과 같은 정보를 확인하려 한다. 깊게 하는 진행이 아니기 때문에 희귀 모델 평가 지표(RMSE,MAE,R^2) 3개로만 결과를 확인하였다.. 기존 종가 데이터만으로 예측을 하였을 때는 예측을 전혀 하지 못하였다.

Research	RMSE	MAE	R^2
Result_1	15.4074	11.3164	-0.0125

<Table 1>

4.4.2 KoBert를 사용하여 pos(긍정), neg(부정) 데이터를 추가하여 예측을 하였을 때는 Result_1에 비해서 RMSE와 MAE는 각각 21.3%와 11.7% 감소했으며, R^2 값은 0.3730으로 개선되었다. 감성분석이 주가에 영향을 미친다는 것을 확인할 수 있던 단계였다.

Research	RMSE	MAE	R^2
Result_2	12.1246	10.0023	0.3730

<Table 2>

4.4.3 **[9]** pos – neg 같은 순 감성 점수(Net Sentiment Score)를 추가하여 전체적인 방향과 영향력을 예측하는 용도로 추가한 Result_2에 비해 RMSE와 MAE가 8.6%와 8.1% 추가로 감소하였다. R^2 값 도 0.4783으로 상승하여, 모델의 설명력이 꾸준히 향상되고 있음을 보여준다.

Research	RMSE	MAE	R^2
Result_3	11.0593	9.1936	0.4783

<Table 3>

4.4.4 하이퍼파라미터와 각 기업별 KOSPI200에 차지하는 비율을 추가한 결과 Result 3에 비해 오차가 더 감소하였다. RMSE는 8.9%, MAE는 12.2% 줄었으며, R^2는 0.5에 근접하여 유의미한 데이터가 도출되었다.

Research	RMSE	MAE	R^2
Result_4	10.0694	8.0649	0.4999

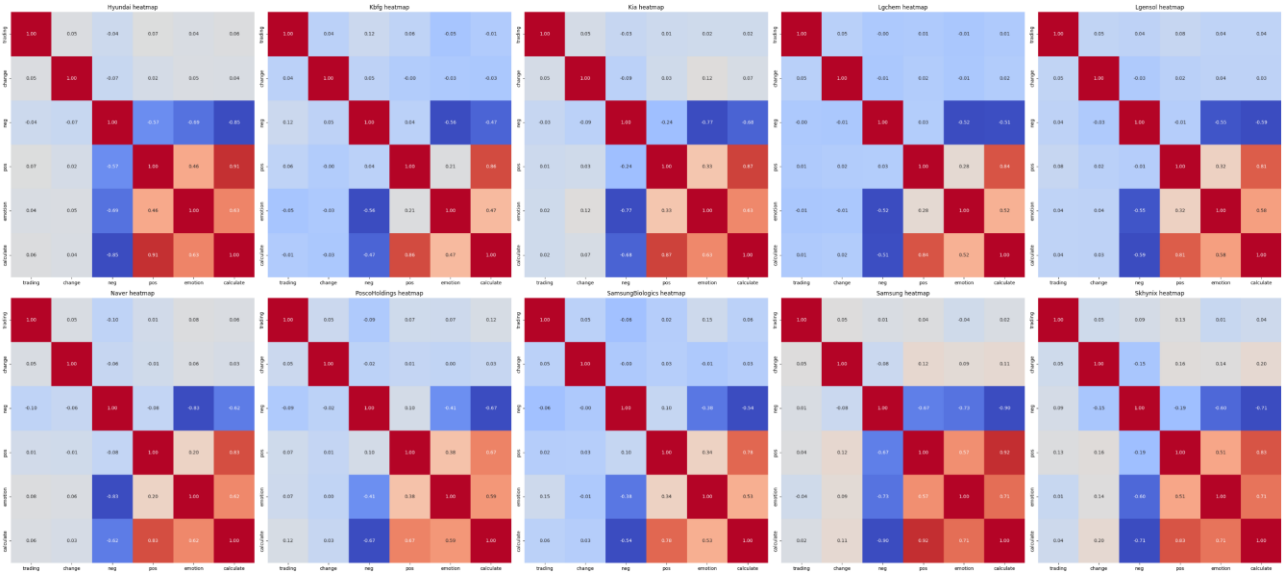
<Table 4>

4.4.5 거래량과 변동성, 그리고 ensemble을 사용하여 나온 결과 개별 실험 결과들에 비해 RMSE는 최소 26.2%, MAE는 최소 24.3% 대폭 감소하였다. R^2 값은 0.7286으로, 많이 개선이 되었다.

Research	RMSE	MAE	R^2
Result_5	7.4357	6.1045	0.7286

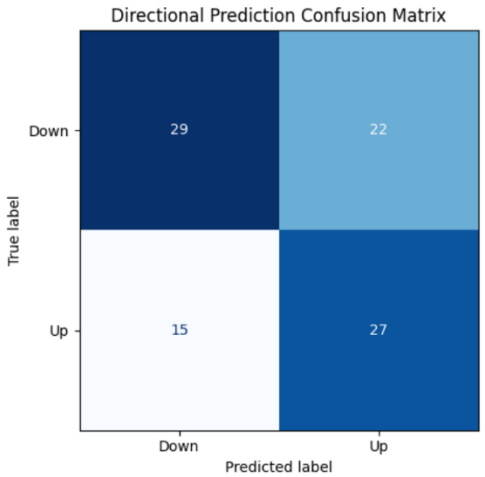
<Table 5>

4.4.6 해당 연구에 <Figure 11>상관관계를 확인해본 결과 거래량(Trading)과 주가(Volume)에 관계와 수익률 (Earning)과 주가(Trading)에 관계가 높은 수준에 양의 상관관계인 것을 확인하였다.

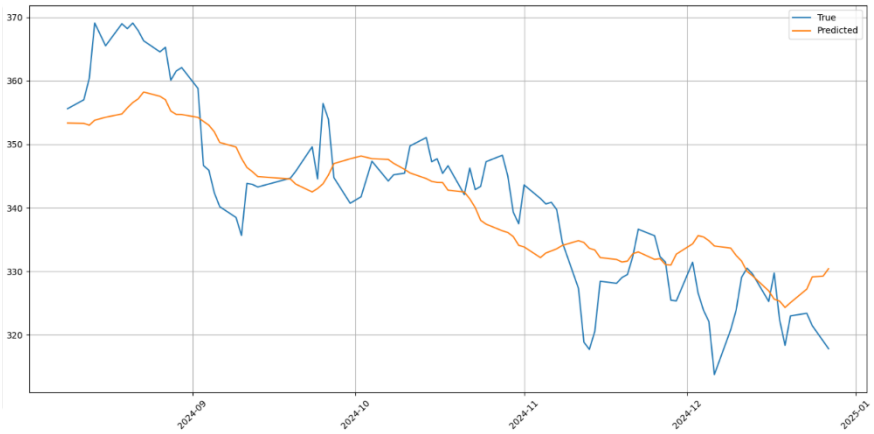


<Figure 11>

그 외에 <Figure 12>혼동 행렬(confusion matrix)로 데이터를 확인한 결과 주가 방향을 60.2%로 예측하는 것을 확인하였다. 추가적인 변수와 하이퍼파라미터 변경 등과 같이 추가하고 조절해야 할 점이 많다는 것을 확인하였다. <Figure 13> 해당 RMSE, MAE, R^2, F1 정보를 기반으로 KOSPI200 그래프와 대조하여 시각화를 하였다. 급격하게 변하는 구간 외에는 잘 따라가는 것 같다.



<Figure 12>



<Figure 13>

4.5 모델 학습 및 평가

평가에 사용한 피처(피처)는 model, data_case, cap_method, Scaler, RMSE, MAE, R^2, MAPE, F1_Score를 사용하였다.

Category	Parameter				
Model	LSTM	CNN	GRU		
Model_parameter	Units [100, 50, 25]		Units [72, 36, 18]		
	Dropout [0.3, 0.15, 0.1]		Dropout [0.25, 0.19, 0.1]		
Time_step	20		21		
Train_ratio	0.7		0.71		
Val_ratio	0.15		0.151		
Data_case	A : 종가, 긍정,부정		B : 종가, 긍정, 부정, 거래량		
	C : 종가, 긍정, 부정, 변동성		D : 종가, 긍정, 부정, 거래량, 변동성		
Cap_method	Cap_on: 기업별 kospi200 차지 비율포함		Cap_on: 기업별 kospi200 차지 비율비포함		
Scaler	MinmaxScaler		SoftmaxScaler		
Performance Metrics	RMSE	MAE	R^2	MAPE	F1 Score

<Table 6>

조건이 총 3584(7*4*2*2*2*4*2*2)개를 학습시켜 각 모델(LSTM, CNN, GRU)별 데이터에서 RMSE, MAE, MAPE가 낮고, R^2, F1_Score가 높은 값을 기준으로 <Table 7 ~16>표로 나타냈다.

4.5.1 LSTM result

model	Model_params	Time_step	Train_ratio	Val_ratio	Data_case
LSTM	Units:[100,50,25] Dropout[0.3,0.15,0.1]	21	0.71	0.151	B
LSTM	Units:[100,50,25] Dropout[0.3,0.15,0.1]	20	0.71	0.151	A
LSTM	Units:[100,50,25] Dropout[0.3,0.15,0.1]	21	0.71	0.151	D

Cap_method	Scaler	RMSE	MAE	R^2	MAPE	F1_Score
Cap_on	Minmax	7.379	5.926	0.726	0.0174	0.637
Cap_on	Minmax	7.726	6.161	0.700	0.0178	0.568
Cap_off	Standard	8.005	6.239	0.678	0.018	0.523

<Table 7>

4.5.2 CNN result [Conv1D 레이어의 하이퍼파라미터(필터 수, 커널 크기)가 코드로 고정되어 있기 때문에, units와 dropout에 대한 단일 파라미터 조합만 사용한다]

model	Model_params	Time_step	Train_ratio	Val_ratio	Data_case
CNN	Units:[50,50,50] Dropout[0.25,0.19 ,0.1]	21	0.7	0.15	C
CNN		20	0.71	0.151	C
CNN		21	0.71	0.151	D

Cap_method	Scaler	RMSE	MAE	R^2	MAPE	F1_Score
Cap_off	Minmax	8.239	6.218	0.694	0.018	0.565
Cap_off	Standard	8.294	6.755	0.654	0.019	0.589
Cap_off	Standard	8.479	6.943	0.638	0.02	0.632

<Table 8>

4.5.3 GRU result

model	Model_params	Time_step	Train_ratio	Val_ratio	Data_case
LSTM	Units:[100,50,25] Dropout[0.3,0.15,0.1]	20	0.71	0.151	C
LSTM	Units:[100,50,25]	21	0.71	0.151	D

	Dropout[0.3,0.15,0.1]				
LSTM	Units:[100,50,25] Dropout[0.3,0.15,0.1]	20	0.71	0.151	D

Cap_method	Scaler	RMSE	MAE	R^2	MAPE	F1_Score
Cap_on	Minmax	7.731	5.919	0.699	0.017	0.556
Cap_on	Minmax	8.014	6.543	0.677	0.019	0.555
Cap_on	Minmax	8.018	6.683	0.677	0.019	0.54

< Table 9>

4.6 **[10]** Ensemble 모델학습 및 평가

Ensemble(LSTM, CNN, GRU, LSTM+CNN, LSTM+GRU, GRU+CNN, LSTM+CNN+GRU)모델을 사용하여 학습하였다. 여러 모델을 사용하는 이유는 5. 에서 서술되어 있다. 본 연구에서 적용한 Seed ensemble과 Hybrid ensemble은 모두 평균 기반 soft voting 방식으로 예측값을 결합하였다. 이는 단순하면서도 안정적인 일반화 성능 확보에 효과적이지만, stacking 기반 메타 학습이나 성능 가중치(weighted voting)를 부여하는 방식과 비교할 때 한계가 존재한다. 따라서 향후 연구에서는 stacking, weighted voting 등 다양한 앙상블 기법을 적용하여 추가적인 성능 개선 가능성을 탐구할 수 있을 것이다.

4.6.1 Ensemble LSTM result

Ensemble_name	Models_in_ensemble	Data_case	Cap_method	Scaler	Time_step
LSTM	Model: LSTM Units:[100,50,25] Dropout[0.3,0.15,0.1]	C	Cap_on	Minmax	21
LSTM	Model: LSTM Units:[100,50,25] Dropout[0.3,0.15,0.1]	A	Cap_on	Minmax	20
LSTM	Model: LSTM Units:[100,50,25] Dropout[0.3,0.15,0.1]	D	Cap_off	Standard	21

Train_ratio	Val_ratio	RMSE	MAE	R^2	MAPE	F1_Score
0.71	0.151	7.662	6.102	0.705	0.0178	0.629
0.71	0.151	7.724	6.242	0.700	0.0120	0.600

0.71	0.151	7.825	6.195	0.692	0.0182	0.625

<Table 10>

4.6.2 Ensemble CNN result

Ensemble_name	Models_in_ensemble	Data_case	Cap_method	Scaler	Time_step
CNN	Model: CNN Units:[50,50,50] Dropout[0.25,0.19 ,0.1]	C	Cap_off	Minmax	21
CNN		C	Cap_off	Standard	20
CNN		D	Cap_on	Minmax	21

Train_ratio	Val_ratio	RMSE	MAE	R^2	MAPE	F1_Score
0.7	0.15	8.239	6.216	0.694	0.0181	0.565
0.71	0.151	8.294	6.755	0.654	0.0199	0.589
0.71	0.151	8.479	6.943	0.638	0.0204	0.632

<Table 11>

4.6.3 Ensemble GRU result

Ensemble_name	Models_in_ensemble	Data_case	Cap_method	Scaler	Time_step
GRU	Model: GRU Units:[100,50,25] Dropout[0.3,0.15,0.1]	A	Cap_on	Minmax	21
GRU	Model: GRU Units:[100,50,25] Dropout[0.3,0.15,0.1]	A	Cap_on	Minmax	20
GRU	Model: GRU Units:[100,50,25] Dropout[0.3,0.15,0.1]	D	Cap_off	Standard	20

Train_ratio	Val_ratio	RMSE	MAE	R^2	MAPE	F1_Score
0.71	0.151	8.068	6.308	0.673	0.0186	0.623
0.71	0.151	8.084	6.668	0.671	0.0195	0.500
0.71	0.151	8.435	6.798	0.642	0.0200	0.580

<Table 12>

4.6.4 Ensemble LSTM+CNN result

Ensemble_name	Models_in_ensemble	Data_case	Cap_method	Scaler	Time_step
LSTM+CNN	Model: LSTM+CNN Units:[100,50,25] Dropout[0.3,0.15,0.1]	D	Cap_on	Standard	20
LSTM+CNN	Model: LSTM+CNN Units:[100,50,25] Dropout[0.3,0.15,0.1]	D	Cap_on	Standard	21
LSTM+CNN	Model: LSTM+CNN Units:[100,50,25] Dropout[0.3,0.15,0.1]	C	Cap_off	Standard	21

Train_ratio	Val_ratio	RMSE	MAE	R^2	MAPE	F1_Score
0.71	0.151	7.764	6.440	0.697	0.0188	0.586
0.71	0.151	7.970	6.573	0.681	0.0191	0.564
0.71	0.151	7.825	6.618	0.676	0.0192	0.512

<Table 13>

4.6.5 Ensemble LSTM+GRU result

Ensemble_name	Models_in_ensemble	Data_case	Cap_method	Scaler	Time_step
LSTM+GRU	Model: LSTM+GRU Units:[100,50,25] Dropout[0.3,0.15,0.1]	A	Cap_on	Minmax	21
LSTM+GRU	Model: LSTM+GRU Units:[100,50,25] Dropout[0.3,0.15,0.1]	C	Cap_on	Minmax	20
LSTM+GRU	Model: LSTM+GRU Units:[100,50,25] Dropout[0.3,0.15,0.1]	C	Cap_off	Standard	21

Train_ratio	Val_ratio	RMSE	MAE	R^2	MAPE	F1_Score
0.71	0.151	7.564	6.065	0.712	0.0178	0.608
0.71	0.151	7.574	6.177	0.711	0.0180	0.540
0.71	0.151	7.575	6.393	0.711	0.0186	0.480

<Table 14>

4.6.6 Ensemble GRU+CNN result

Ensemble_name	Models_in_ensemble	Data_case	Cap_method	Scaler	Time_step
GRU+CNN	Model: GRU+CNN Units:[100,50,25] Dropout[0.3,0.15,0.1]	D	Cap_on	Minmax	20
GRU+CNN	Model: GRU+CNN Units:[100,50,25] Dropout[0.3,0.15,0.1]	A	Cap_on	Minmax	20
GRU+CNN	Model: GRU+CNN Units:[100,50,25] Dropout[0.3,0.15,0.1]	C	Cap_on	Standard	21

Train_ratio	Val_ratio	RMSE	MAE	R^2	MAPE	F1_Score
0.71	0.151	8.285	6.583	0.655	0.0194	0.653
0.71	0.151	8.365	6.797	0.648	0.0200	0.534
0.71	0.151	8.408	7.255	0.644	0.0211	0.459

<Table 15>

4.6.7 Ensemble LSTM+GRU+CNN result

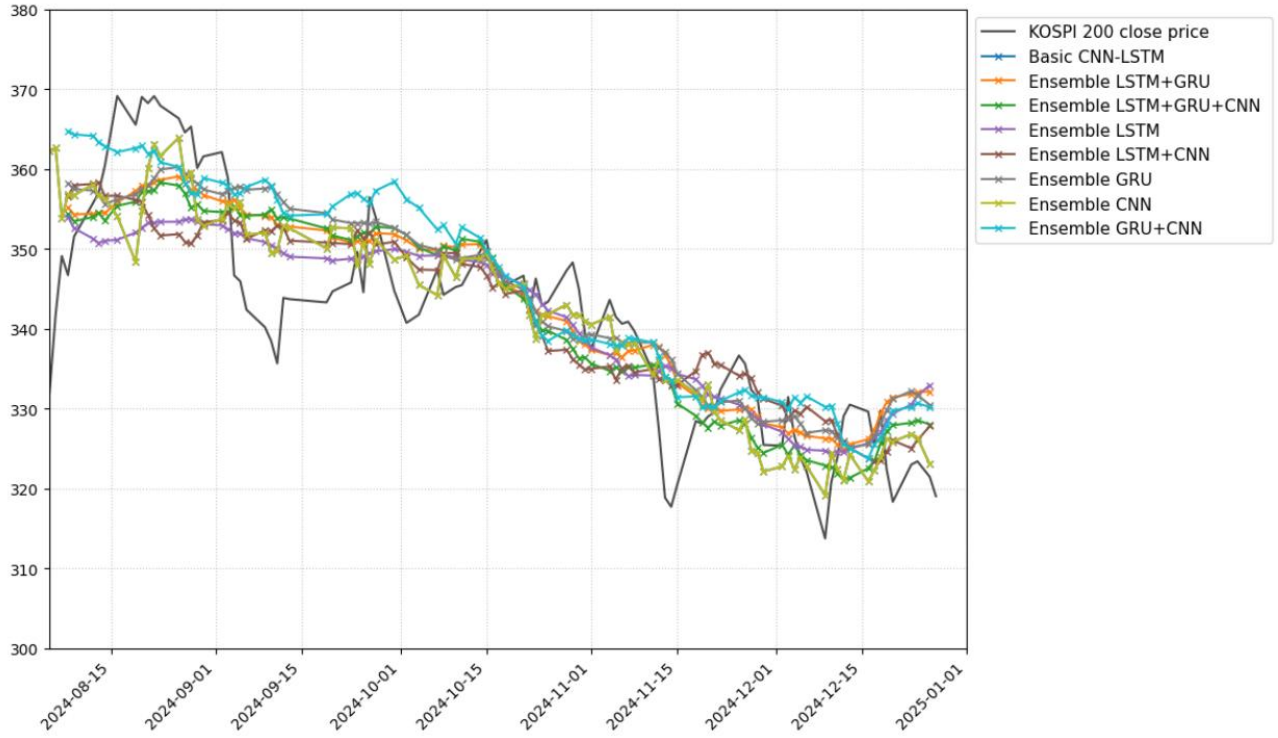
Ensemble_name	Models_in_ensemble	Data_case	Cap_method	Scaler	Time_step
LSTM+GRU+CNN	Model: LSTM+GRU+CNN Units:[100,50,25] Dropout[0.3,0.15,0.1]	C	Cap_on	Minmax	20
LSTM+GRU+CNN	Model: LSTM+GRU+CNN Units:[100,50,25] Dropout[0.3,0.15,0.1]	A	Cap_on	Minmax	21
LSTM+GRU+CNN	Model: LSTM+GRU+CNN Units:[100,50,25] Dropout[0.3,0.15,0.1]	C	Cap_on	Standard	21

Train_ratio	Val_ratio	RMSE	MAE	R^2	MAPE	F1_Score
0.71	0.151	7.573	6.262	0.711	0.0183	0.541
0.71	0.151	7.750	6.274	0.698	0.0183	0.512
0.71	0.151	7.785	6.362	0.695	0.0185	0.493

<Table 16>

5. Results & Evaluation

KOSPI200 주가예측에 대해서 각 모델별로 상위 데이터 3개를 사용하여 그래프와 대조한 후 적합한 데이터가 1개를 뽑아 10개를 <Figure 14>그래프와 대조해 보았다. 가장 근접하고, 평가지표가 좋은 데이터 2개를 찾아 <Table 17>에 표로 나타내었다.



<Figure 14>

5.1 Best Ensemble result

Ensemble_name	Models_in_ensemble	Data_case	Cap_method	Scaler	Time_step
LSTM+GRU	Model: LSTM+GRU Units:[100,50,25] Dropout[0.3,0.15,0.1]	C	Cap_on	Minmax	20
LSTM+GRU+CNN	Model: LSTM+GRU+CNN Units:[100,50,25] Dropout[0.3,0.15,0.1]	C	Cap_on	Minmax	20

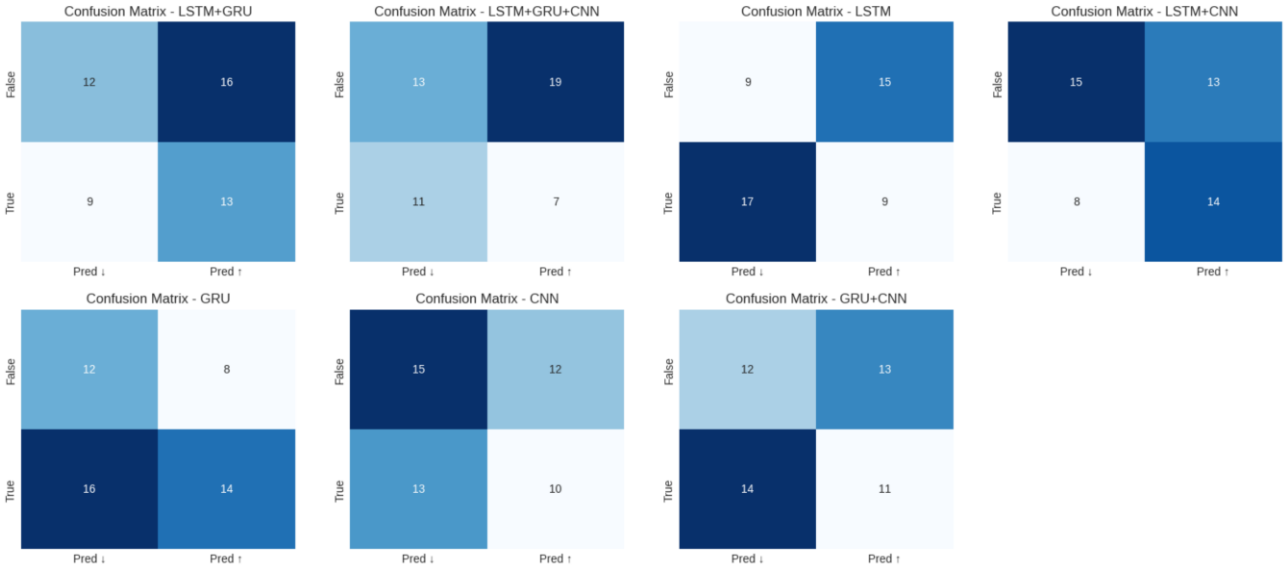
Train_ratio	Val_ratio	RMSE	MAE	R^2	MAPE	F1_Score
0.71	0.151	7.564	6.065	0.712	0.0178	0.608
0.71	0.151	7.573	6.262	0.711	0.0183	0.541

<Table 17>

본 연구에서 수행한 다양한 모델 학습 및 비교 실험의 결과, 가장 우수한 성능은 LSTM+GRU와 LSTM+GRU+CNN Hybrid ensemble에서 나타났다. 특히 Case C(감성+변동성) 입력 조건과 Cap_on 방식, MinMax 정규화를 적용한 조합에서 LSTM+GRU 모델은 RMSE 7.564, MAE 6.065, R^2 0.712, MAPE 0.0178, F1 Score 0.608을 기록하였다. 이는 단일 LSTM 모델에 비해 예측 오차가 감소하고 설명력이 향상된 수치로, 장기 추세를 반영하는 LSTM과 단기 변동성을 포착하는 GRU가 상호 보완적으로 작용했음을 보여준다.

동일한 조건에서 학습한 LSTM+GRU+CNN 모델 역시 RMSE 7.573, MAE 6.262, R^2 0.711이라는 근접한 성능을 나타냈으며, 이는 CNN이 단기 급등락과 같은 지역적 패턴을 보완적으로 학습했기 때문이다. 두 모델 모두 기존의 단일 구조 대비 안정적이고 강건한 결과를 보였으며, 특히 LSTM+GRU 모델은 모든 지표에서 균형 잡힌 성능을 나타내어 최종적으로 가장 성능이 좋은 모델로 선정되었다.

이러한 결과는 단일 감성 기반 입력보다 거래 특성(변동성)의 반영이 필수적이며, 단일 모델보다 Hybrid ensemble 접근이 금융 시계열 예측에서 더 높은 일반화 성능을 제공함을 증명한다. 따라서 본 연구의 최종 결론은 뉴스 감성 지표와 거래 특성을 결합한 다변량 입력을 기반으로 한 LSTM+GRU Hybrid ensemble이 KOSPI200 T+1 예측에 가장 효과적인 방법론이라는 점이다.



<Figure 15>

<Figure 15> 추가적으로, 각 모델의 방향성 예측 성능을 혼동행렬(Confusion Matrix)로 분석하였다. LSTM+GRU와 LSTM+GRU+CNN 모델은 RMSE, MAE, R^2 등 회귀 지표에서는 우수한 성능을 보였으나, 방향성 분류에서는 상승(Up) 클래스에 대한 Recall이 낮아 전체 F1 Score가 제한적으로 나타났다. 이는 금융 시계열의 특성상 미세한 등락을 강제로 상승, 하락으로 구분하는 과정에서 발생한 오분류 때문이며, 실제로 혼동행렬에서도 Up 클래스가 Down으로 분류되는 비율이 높게 관찰되었다. 반면 CNN과 GRU+CNN 모델은 단기 패턴 학습 능력 덕분에 방향성 분류 정확도(Accuracy)가 상대적으로 높은 결과를 나타냈다. 따라서 본 연구의 결과는 회귀 기반의 예측 정확도는 Hybrid 모델이 가장 우수하나, 방향성 분류 정확도는 CNN 구조가 부분적으로 강점을 가진다는 점을 보여준다. 이는 향후 연구에서 보합 구간을 별도의 클래스(상승, 하락, 보합)로 확장하거나, 외부 거

시 변수(환율, 금리, 해외 지수 등)를 추가 입력으로 반영함으로써 방향성 예측 성능을 개선할 필요가 있음을 시사한다. 이는 향후 연구에서 보합 구간을 별도의 클래스(상승/하락/보합)로 확장하거나, 외부 거시 변수(환 율, 금리, 해외 지수 등)를 추가 입력으로 반영함으로써 방향성 예측 성능을 개선할 필요가 있음을 시사한다.

6. Conclusion

전체적인 방향성은 **[11]** *Application of an ANN and LSTM-based Ensemble Model for Stock Market Prediction*. 라는 논문을 참조하였다. 한국어 뉴스 감성과 거래 특성을 결합한 다변량 입력을 활용하고 입력 특성에 따른 비교 실험에서는 뉴스 감성만 사용했을 때보다 감성+거래 특성(거래량·등락률)을 결합했을 때 성 능 향상이 뚜렷하게 나타났다. 감성 데이터만 사용한 경우 예측이 단기적 이벤트에 과민하게 반응하는 경향이 있었으나, 거래 특성을 함께 반영하면 시장 참여자의 실제 매매 활동이 내재화 되면서 노이즈가 줄어드는 모습을 보였다. 이는 기존 연구들이 주로 감성에만 의존했던 한계를 넘어, 거래 특성을 함께 고려하는 융합형 접근 이 KOSPI200 예측에 유효함을 보여준다.

연구 결과, 감성+거래 특성 융합이 단일 감성 기반 접근보다 예측 정확도를 높였으며, Hybrid ensemble 기법은 변동성이 큰 금융 데이터에서도 안정적 성능을 확보하는 데 기여하였다. 또한 방송사,경제지의 이원 가중 집계 방식을 통해 국내 언론 생태계의 특수성을 반영한 점은 기존 해외 중심 연구와 차별점이 있다.

학문적 기여는 크게 세 가지로 요약된다. 첫째. 뉴스 감성과 거래 특성의 동시 반영을 통한 설명력 강화, 둘째. Hybrid ensemble을 통한 일반화 성능 개선, 셋째. 한국 시장 특화 가중 집계 방식을 통한 데이터 신뢰성 제고이다. 실제 활용 측면에서도, 본 연구의 접근은 기관 투자자나 리스크 관리 부 서가 단기 지수 변동 예측에 참고할 수 있는 근거 자료가 될 수 있다.

다만 본 연구는 세 가지 한계를 가진다. 첫째, 데이터 구간이 3년으로 한정되어 있어 장기적 패턴을 반영하기 어렵다. 둘째, 감성 분석 모델(KoBERT fine-tuning)의 도메인 적합성이 제한적일 수 있다. 셋째, 거래 특성으로 거래량·등락률만을 포함했으며, 금리·환율·글로벌 지표 등 외생 변수는 배제되었다. 향후 연구에서는 금융·거시 지표를 포함한 확장형 입력, Transformer 계열 모델과의 비교, 강화학습 기반 투자전략 시뮬레이션으로 발전시킬 필요가 있다. 넷째, 학습과정에서 batch size와 같은 정보를 크게 진행하고 싶었지만 GPU 문제로 진행을 하지 못하였다. 금리, 금값 등을 추가해 보고, 학습을 진행할 때는 batch size를 변경하여 진행해볼 예정이다.

참고문헌

[1] 박주현, 박현지 and 김영범. (2024). 빅카인즈를 활용한 5.18 관련 국내 기사 분석 연구. 정보관리학회지, 41(1), 107-132.

[2] *KOSPI index prediction using topic modeling and LSTM 1)Jin-Hyeon Joo*, Geun-Duk Park**2024*

[3] *Combining News Sentiment and Technical Analysis to Predict Stock Trend Reversal /Luca Cagliero, Giuseppe Attanasio, Paolo Garza, Elena Baralis /2019*

[4] *감정분석과 GRU 모델 기반의 주가지수 예측 및 분석: 코스피 200 에너지/화학을 중심으로 / 양혁진* 1 , 최종민* 2 , 박찬정**/ 2024*

[5] *Performance of Deep Learning in Prediction of Stock Market Indicators / Hongjoong KIM, PhD, Kyoung-Sook MOON, PhD /2019*

[6] 임상택, 김준영, 아마드 모리 자데 카키 and 최아영. (2025). 딥러닝 기반 지역별 한계 가격제 예측 기술 개발. 한국차세대컴퓨팅학회 논문지, 21(2), 49-61.

[7] https://github.com/SKTBrain/KoBERT - kobert
한국어 논문 요약을 위한 KoBART와 KoBERT 모델 비교* / 전제성, 이수안 / 제34회 한글 및 한국어 정보처리 학술대회 논문집 (2022년) – 3.1.1 kobert설명

[8] 김수아, 권미주 and 김현희. (2024). 생성 AI기반 뉴스 감성 분석과 부동산 가격 예측: LSTM과 VAR모델의 적용. 정보처리학회 논문지, 13(5), 209-216.

[9] Reichheld, F. F. (2003). The one number you need to grow. *Harvard Business Review*, *81*(12), 46-54.

[10] 유서아 and 김용혁. (2024). 예측 성능 향상을 위한 새로운 가중치 기반 앙상블 기법 제안. 아시아태평양융합연구교류논문지, 10(12)

[11] Liu, F., et al. (2024). *Application of an ANN and LSTM-based Ensemble Model for Stock Market Prediction*. arXiv. https://doi.org/10.48550/arXiv.2410.20253/

<Figure 1>
BERT input representation. The input embeddings are the sum of the token embeddings, the segmentation embeddings and the position embeddings.

<Figure 2>
Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). *Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation*. arXiv.

<Figure 3>
Richard S. Sutton. Two problems with backpropagation and other steepest-descent learning procedures for networks, 1986.

<Figure 4>
Wojciech Zaremba and Ilya Sutskever. Learning to Execute. pages 1–25, 2014.

<Figure 5>
Matthew D. Zeiler. ADADELTA: An Adaptive Learning Rate Method. arXiv preprint arXiv:1212.5701, 2012.

<Figure 6>
Wang, W., & Lu, Y. (2018). An analysis of the performance of mean absolute error and root mean square error in predicting daily average global horizontal irradiance. Journal of Applied Meteorology and Climatology, 57(1), 167-182.

<Figure 7>
Willmott, C. J., & Matsuura, K. (2005). The use of the mean absolute error (MAE) in an assessment of the predictive accuracy of a global climate model. Climatic Change, 72(1), 21-36.

<Figure 8>
Bock, T. et al. (2018). Understanding the limitations of the mean absolute percentage error (MAPE) as a measure of forecast accuracy. International Journal of Forecasting, 34(3), 517-531.
<Figure 9>
Dynamic UNet, Unet model using PixelShuffle ICNR upsampling that can be built on top of any preTrained architecture, https://docs.fast.ai/vision.models.unet.html (November 1, 2024).
<Figure 10>
Young, P. H. (2000). The coefficient of determination (R-squared) is more powerful than is often believed. A. W. W. A. Journal, 92(1), 162-167.
<Figure 11>
4.4.5에 결과에 해당하는 hitmap
<Figure 12>
4.4.5에 해당하는 정확도를 계산하기 위해 confusion matrix 사용. 결과적으로 60.2%라는 값을 도출.
<Figure 13>
해당 RMSE, MAE, R^2, F1 정보를 기반으로 KOSPI200 그래프와 대조하여 시각화.
<Figure 14>
학습한 결과에서 가장 근접한 데이터 1개씩, 총 8개를 사용하여 대조.
[Reichheld, F. F. (2003). The one number you need to grow. *Harvard Business Review*, *81*(12), 46-54.]
<Table 1>
순수 종가로 학습한 결과.
<Table 2>
pos(긍정), neg(부정) 피처를 추가하여 학습한 결과.
<Table 3>
Pos – neg, 라는 순 감성 점수 계산식을 추가하여 학습한 결과.
<Table 4>
각 기업이 KOSPI200에 차지하는 비율을 추가하여 학습한 결과.
<Table 5>
Ensemble을 사용하여 학습한 결과.
<Table 6>
전체적으로 사용할 조건 정리.
<Table 7>
LSTM 학습 상위 3개 결과.
<Table 8>
CNN 학습 상위 3개 결과.
<Table 9>
GRU 학습 상위 3개 결과.
<Table 10>
Ensemble LSTM 학습 상위 3개 결과.
<Table 11>
Ensemble CNN 학습 상위 3개 결과.
<Table 12>
Ensemble GRU 학습 상위 3개 결과.
<Table 13>
Ensemble LSTM+CNN 학습 상위 3개 결과.
<Table 14>

Ensemble LSTM+GRU 학습 상위 3개 결과.

<Table 15>

Ensemble GRU+CNN 학습 상위 3개 결과.

<Table 16>

Ensemble LSTM+GRU+CNN 학습 상위 3개 결과.

<Table 17>

가장 결과가 좋다고 판단한 데이터 2개.