감성 및 거래 특성을 반영한 시계열 딥러닝 앙상블을 통한 KOSPI200 지수 예측 연구

박재현 박종원 | 팀명:
박박박사

목차

1. 연구 개요
2. 연구 배경 및 목적
3. 연구의 주요 기여점
4. 선행 연구 분석
5. 연구 방법론 개요
6. 감성 분석 모델 설명
7. 감성 분석 과정
8. 시계열 예측 모델 설명
9. 데이터 수집 및 전처리
10. 모델 학습 및 최적화
11. 모델 구조 및 설계
12. 모델 평가 지표
13. 백테스팅
14. 연구 결과

연구 개요

KOSPI200 지수 예측을 위한 감성 및 거래 특성 기반 시계열 딥러닝 앙상블 모델



https://www.wayful.com/p/krx-kospi200-index-forecast.html

본 연구는 2022.01.27~2024.12.30 기간의 KRX 가격·거래량 데이터와 빅카인즈 뉴스 데이터를 통합하여 KOSPI200 지수의 T+1 종가를 예측하는 모델을 개발

뉴스 데이터는 KoBERT 기반 이진 분류를 통해 기사별 긍·부정 확률을 산출하고, 국내 미디어 특성을 반영해 방송사와 경제지에 3:1 가중치를 적용하여 기업·일자별 감성 지표로 집계

입력 데이터는 KOSPI200 상위 10개 종목의 긍정·부정·감성·순감성·거래량·변동률 6개 특성(총 60차원)으로 구성했으며, 21일 이동 윈도우 방식을 적용

데이터는 학습/검증/테스트를 71/15.1/13.9 비율로 분할했으며, 정규화는 학습 구간 통계 기반 MinMax 방식을 일관되게 적용

[MinMax가 SofrMax보다 민감하기 때문에 적합하다 판단]

연구 배경 및 목적

금융시장에서 주가 예측의 중요성

- 주가 예측은 투자 의사결정, 기업 가치 평가, 리스크 관리 등 다양한 영역에서 핵심적 역할 수행
- 주가는 거시경제 지표, 기업 실적, 투자 심리, 외부 충격 등 복합적 요인에 의해 결정
- 최근 연구들은 비정형 데이터, 특히 뉴스 텍스트를 활용하여 시장 참여자의 심리를 정량화하는 시도 활발
- 전통적인 가격 및 거래량 기반 예측 모델의 한계를 보완하는 혁신적 접근법으로 주목

한국어 뉴스 감성과 거래 특성을 결합한 접근법

- 한국어 뉴스 감성과 거래 특성을 결합한 다변량 시계열 입력 구조 제안
- Hybrid ensemble 기법을 활용한 LSTM 모델을 통해 KOSPI200의 다음날 종가 수준 예측
- 코로나19 이후 시장 안정화 고려, LG에너지솔루션 상장일(2022.01.27)부터 2024.12.30까지 데이터 활용
- 빅카인즈 뉴스 데이터와 KRX 가격 및 거래량 데이터 통합 분석

연구의 주요 기여점

국내 언론 생태계를 반영한 이원 가중 감성 집계식 제안	기업별 감성지표와 거래 특성을 결합한 다변량 시계열 입력 구조 설계	단일 모델 변동성을 완화하는 앙상블로 일반화 성능 강화
- 방송사(1군)와 경제지(2군)를 구분한 이원 가중 감성 집계식 제안 - 국내 보도 생태계에 맞게 방송사와 경제지를 3:1 비율로 가중치 적용 - 매체 영향력 차이를 반영한 선행 연구의 플랫폼 가중치 논의 참고 - 검증 세트 성능과 민감도 분석 (2:1~4:1)으로 가중치 최적화 - 국내 언론 환경에 특화된 감성 집계 방식으로 예측 정확도 향상	- 기업별 감성지표 (긍정·부정·감성·순감성) 와 거래 특성 (거래량·변동률) 결합 - KOSPI200 상위 10개 종목에 대한 6개 특성을 통합한 60차원 입력 벡터 구성 - 21일 이동 윈도우 기반 시계열 입력 구조 설계 - 감성과 거래 특성의 상호작용을 포착하는 다변량 접근법 개발 - 한국 시장 특성에 최적화된 입력 설계로 예측 성능 향상	- LSTM과 GRU를 결합한 하이브리드 앙상블 모델 채택 - 단일 모델의 분산을 낮추고 일반화 성능 개선 - 서로 다른 초기 시드로 학습한 모델 결과를 평균화(소프트 보팅) - LSTM+GRU, LSTM+CNN+GRU 등 다양한 앙상블 조합 실험 - 변동성이 큰 금융시계열에서도 안정적인 예측 성능 확보

선행 연구 분석 (1)

주가 예측 관련 기존 연구 동

- 'KOSPI Index Prediction using Topic Modeling and LSTM': 뉴스 기사 형태소 분석 후 LDA 기반 토픽 모델링 적용, LSTM 모델과 결합하여 KOSPI 지수 예측
- 'Combining News Sentiment and Technical Analysis to Predict Stock Trend Reversal': 뉴스와 소셜미디어의 감성 분석 및 기술적 지표를 통합하여 주가 반전 시점 탐지
- '감정 분석과 GRU 모델 기반의 주가지수 예측 및 분석': 한국어 뉴스를 KoBERT 기반 감성 분석 후 GRU 모델에 적용, KOSPI200 에너지/화학 업종 예측

기존 연구의 한계점 및 본 연구의 차별성

- 기존 연구들은 주로 뉴스 감성만 활용하거나, 특정 섹터에 국한되거나, 모델 성능 자체에 집중하는 경향
- 본 연구는 방송사/경제지 이원 가중 집계식, 거래 특성과 결합된 다변량 입력 설계, Hybrid ensemble LSTM을 통한 일반화 성능 개선을 통해 차별화
- 한국어 기반 KOSPI200 예측에 특화된 접근법으로, 국내 언론 생태계와 시장 특성을 반영한 모델 구축
- 단일 감성 지표가 아닌 감성과 거래 특성의 상호작용을 포착하는 통합적 접근법 제시

선행 연구 분석 (2)

감정 분석과 GRU 모델 기반의 주가지수 예측 및 분석

- 한국어 뉴스를 KoBERT 기반 감성 분석 후 GRU 모델에 적용
- KOSPI200의 에너지, 화학 업종을 대상으로 예측 수행
- 감성 분석을 활용한 점에서 본 연구와 유사
- 거래 특성을 고려하지 않고 특정 업종에 제한된 한계 존재

Performance of Deep Learning in Prediction of Stock Market

- LSTM, CNN 등 딥러닝 모델들의 성능을 비교하여 주가 예측 가능성 검증
- 특정 데이터 셋보다는 모델의 구조적 성능 차이에 초점
- 뉴스 감성이나 거래 특성과의 결합은 다루지 않음
- 모델 자체의 성능에만 집중하는 한계 존재

연구 방법론 개요

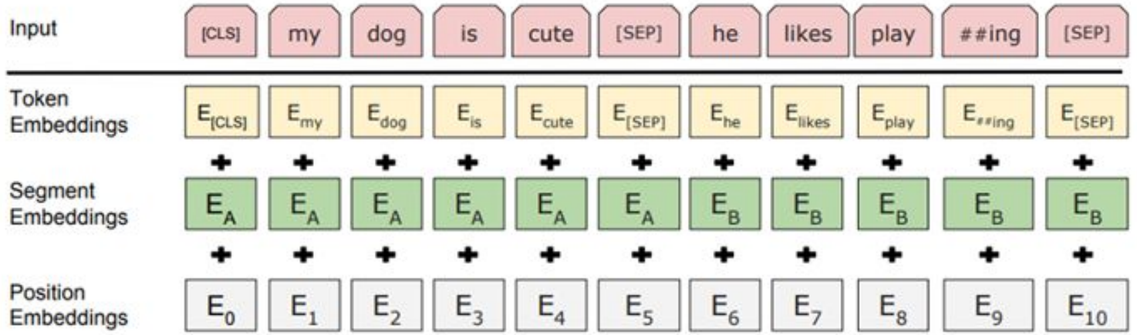
본 연구는 크게 두 단계로 진행된다.

- 첫째, 뉴스 텍스트 감성 분석 단계에서는 KoBERT를 활용하여 기사별 긍정 및 부정 감성을 추출한다.
- 둘째, 시계열 예측 단계에서는 감성 확률과 거래 특성(거래량 및 변동률)을 다변량 입력으로 활용하여 LSTM, GRU, CNN-LSTM 및 Seed Ensemble 기반 예측을 수행한다.

- 본 연구는 한국어 뉴스 감성과 거래 특성을 결합한 다변량 시계열 입력 구조를 제안함
- KoBERT를 활용한 감성 분석으로 기사별 긍·부정 확률을 산출하고, 방송사와 경제지에 3:1 가중을 적용하여 기업·일자별 감성 지표로 집계
- 입력은 상위 10개 종목의 긍정·부정·감성·순감성·거래량·변동률 6개 특성(총 60차원)으로 구성
- 데이터는 학습/검증/테스트 71/15.1/13.9로 분할, 정규화는 학습 구간 통계 기반 MinMax를 일관 적용
- LSTM과 GRU를 결합한 하이브리드 앙상블을 채택해 단일 모델 분산을 낮추고 성능을 개선

감성 분석 모델

본 연구에서는 사전 검증 결과 가장 우수한 성능을 보인 KoBERT를 최종적으로 선택했다. KoBERT는 SKTBrain에서 개발한 한국어 특화 BERT 모델로, BERT 구조를 한국어 데이터에 맞게 재학습시킨 모델이다.



KoBERT 모델 구조

- Transformer 인코더 기반
- 다층 Self-Attention 메커니즘
- 양방향 문맥 정보 학습
- 사전 학습된 모델 활용
- 한국어 특화 임베딩

WordPiece 토크나이저

- 서브워드 단위로 분절
- 형태소 분석 문제 최소화
- 띄어쓰기 관련 문제 해결
- 미등록 단어 처리 용이
- 효율적인 어휘 표현

감성 분류 방식

- 긍정(Pos)과 부정(Neg) 이진 분류
- SoftMax 분류기 활용
- 문장별 감성 확률 산출
- 방송사와 경제지 이원 가중치(3:1) 적용
- 일일 감성 지표 도출

SKTBrain/KoBERT: Korean BERT pre-trained cased (KoBERT) (github.com)

감성 분석 과정

텍스트 데이터 전처리 및 변환	문맥 임베딩 생성	감성 확률 집계 및 활용
- 뉴스 기사 제목과 본문 수집 - 중복 기사 제거 및 한국어 기사만 선별 - WordPiece 토크나이저로 서브워드 단위 분절 - 임베딩층에서 벡터 표현으로 변환 - 기업별, 날짜별로 데이터 정리	- 다층 Self-Attention 메커니즘 적용 - 양방향 문맥 정보 학습 - 문장 내 단어 간 관계 포착 - 풍부한 문맥 임베딩 생성 - 한국어 특화 언어 모델 활용 - 금융 도메인 특성 반영	- SoftMax 분류기로 긍정/부정 확률 산출 [본래 Sigmoid가 이진분류에 더 적합하지만 결과가 SoftMax가 더 좋았기 때문에 선정] - 방송사와 경제지에 3:1 이원 가중치 적용 - 기업별, 일자별 감성 지표 집계 - 순 감성 점수(긍정-부정) 계산 - 시계열 모델의 입력 피처로 활용 - 감성 지표와 거래 특성 결합

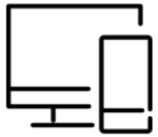
시계열 예측 모델: LSTM

LSTM은 RNN의 장기 의존성 문제를 해결하기 위해 고안된 구조로, 입력 게이트(Input Gate), 망각 게이트(Forget Gate), 출력 게이트(Output Gate)로 구성된다. 시점 t에서 입력(xt), 은닉 상태(ht), 셀 상태(ct)는 게이트 메커니즘을 통해 갱신된다.



게이트 구조

- 입력 게이트: 새 정보 저장 제어
- 망각 게이트: 기존 정보 유지/삭제
- 출력 게이트: 출력 정보 제어
- 셀 상태: 장기 메모리 역할
- 은닉 상태: 현재 출력값 결정



장기 의존성 처리

- 기울기 소실 문제 해결
- 장기 패턴 학습 가능
- 시간적 의존성 포착
- 선택적 정보 유지 및 갱신
- 복잡한 시퀀스 패턴 인식



금융 시계열 적용

- 금융 시계열의 장기 추세 학습
- 주가 변동의 복잡한 패턴 포착
- 비선형적 관계 모델링
- 다변량 입력 처리 가능
- 예측 정확도 향상

시계열 예측 모델: GRU

GRU는 LSTM의 단순화된 변형으로, 업데이트 게이트와 리셋 게이트만으로 상태 전이를 제어한다. 이 구조는 파라미터 수를 줄여 학습 효율성을 높이면서도 장단기 의존성을 모두 학습할 수 있다는 장점이 있다.

간소화된 구조

- LSTM보다 단순한 구조
- 셀 상태 없이 은닉 상태만 사용
- 파라미터 수 감소
- 계산 효율성 향상
- 메모리 사용량 절감

게이트 메커니즘

- 업데이트 게이트: 정보 갱신 제어
- 리셋 게이트: 이전 정보 활용 정도 결정
- 후보 은닉 상태 생성
- 최종 은닉 상태 계산
- 선택적 정보 전달

LSTM과의 비교

- 학습 속도: GRU가 더 빠름
- 파라미터 수: GRU가 더 적음
- 메모리 효율성: GRU가 우수
- 소규모 데이터셋: GRU 유리
- 복잡한 시퀀스: LSTM 유리

시계열 예측 모델: CNN-LSTM

CNN-LSTM은 합성곱 신경망(CNN)과 LSTM을 결합한 하이브리드 구조로, 금융 시계열 분석에 적합합니다. CNN은 단기적 패턴을 추출하고, LSTM은 장기 의존성을 학습하여 단기 이벤트와 장기 추세를 동시에 반영할 수 있습니다. 본 연구에서는 CNN-LSTM을 보조 실험 모델로 활용하여 단기 충격의 영향을 검증하였습니다.

합성곱 신경망(CNN)

- 입력 시계열에서 단기적인 국소 패턴 추출
- 급격한 가격 변동과 같은 특징 포착
- 필터를 통한 특징 맵(feature map) 생성
- 시계열 데이터의 지역적 패턴 학습
- 금융 데이터의 단기 충격 감지에 효과적

LSTM 구조

- 장기 의존성 학습에 특화된 구조
- 입력/망각/출력 게이트로 정보 제어
- 과거 정보의 선택적 기억과 망각
- 시계열의 장기 추세 파악 가능
- 금융 시장의 장기적 흐름 포착에 적합

하이브리드 모델의 장점

- 단기 이벤트와 장기 추세 동시 반영
- CNN: 지역적 특징 추출, LSTM: 시간적 의존성 학습
- 금융 시계열의 복잡한 패턴 포착 가능
- 급격한 변동과 장기 추세 모두 고려
- 예측 정확도와 안정성 향상

시계열 예측 모델: Seed Ensemble

Seed Ensemble은 동일한 모델 구조(LSTM)를 서로 다른 초기 시드(Seed)로 학습한 후, 예측 결과를 평균화(소프트 보팅)하는 기법입니다. 이 방법은 초기 파라미터 설정 차이로 인한 결과 변동성을 줄이고, 모델의 분산을 감소시켜 전반적인 일반화 성능을 개선합니다. 본 연구에서는 LSTM을 5회 반복 학습하여 Seed Ensemble을 구성했습니다.

다중 초기화 학습

- 동일 모델 구조를 다른 초기 시드로 학습
- 무작위 초기화에 따른 학습 경로 다양화
- 각 모델은 동일 구조지만 다른 파라미터 보유
- 5회 이상의 반복 학습으로 안정성 확보
- 개별 모델의 편향 감소 효과

소프트 보팅(Soft Voting)

- 각 모델의 예측 결과를 평균화하는 방식
- 단순 평균으로 최종 예측값 도출
- 극단적 예측값의 영향력 완화
- 개별 모델의 예측 오차 상쇄 효과
- 안정적인 예측 결과 제공

하이브리드 앙상블 확장

- LSTM+GRU, LSTM+CNN+GRU 조합 구성
- 서로 다른 모델 구조의 장점 결합
- 단일 모델 대비 예측 오차 감소
- 모델 분산 감소로 일반화 성능 향상
- 금융 시계열의 복잡한 패턴 포착 강화

데이터 수집 및 전처리: 비정형 데이터



뉴스 데이터 수집

- 수집 기간: 2022년 1월 27일(LG에너지솔루션 상장일)부터 2024년 12월 30일까지
- 데이터 출처: 한국언론진흥재단의 빅카인즈
- 수집 대상: KOSPI200 지수 상위 10개 기업(현대차, KB금융, 기아, LG화학, LG에너지솔루션, 네이버, 포스코홀딩스, 삼성바이오로직스, 삼성전자, SK하이닉스)
- 언론사 분류: 1군(방송사 및 경제지)과 2군(대한경제, 매일경제, 머니투데이 등 12개 언론사)으로 구분

	일자	제목	키워드	본문
31	20241231	함영주 하나금융 회장, 자사주 5천주 매입 "밸류업 박차 가할 것"	회장,함영주,금융,자사,매입,밸류업,박차,회장,함영주,금융,그룹,금융,경영진,자사주...	[머니투데이 이병권 기자] \n함영주 하나금융그룹 회장을 비롯한 하나금융 주요 경영...
14	20241231	10년간 6번 연초 효과 내년에도 통할까	10년,효과,연초,내년,증시,전망,금리,전망,연초,코스피,향냥,좌우,두각,연초,효과...	[이데일리 김응태 기자] 최근 10년 동안 코스피 지수가 1월에 플러스(+) 수익률...
15	20241231	비트코인 투기 때문에 한국 증시 폭락? "양의 상관관계 깨졌다"	비트,코인,투기,폭락,한국,증시,상관관계,은행,파산,비트코인,투자자,자금,주식시장,...	은행 파산 속 값 오른 비트코인 [연합]\n\n\n[헤럴드경제=김보영 기자] 국내...
17	20241231	기업공시[12월 31일]	기업공시,12월,31일,코스피,공시,삼성에스디에스,삼성전자,한신공영,규모,ITO,서...	<코스피 공시> \n \n\n ▲삼성에스디에스(018260)=삼성전자(005930)...
51	20241231	삼성전자, 레인보우로보틱스 최대주주로 미래로봇 개발 가속화	삼성전자,레인보우로보틱스,최대,주주,미래로봇,가속,2670억,추가,투자,확보,지분,...	약 2670억원 추가 투자해 지분 35.0% 확보 \nAI 이어 로봇 회사까지 대형...

데이터 전처리 및 품질 관리

- 중복 기사 제거: 제목과 날짜 기준으로 중복 기사 필터링
- 언어 필터링: 한국어 기사만 선별하여 데이터 품질 관리
- 감성 분석: KoBERT 모델을 활용한 긍정 및 부정 확률 산출
- 가중치 적용: 방송사와 경제지에 3:1 비율의 이원 가중 집계방식 적용

데이터 수집 및 전처리: 정형 데이터



거래 데이터 수집

- 데이터 출처: KRX(한국거래소)에서 제공하는 KOSPI200 지수 데이터
- 수집 기간: 2022년 1월 27일부터 2024년 12월 30일까지(비정형 데이터와 동일)
- 수집 항목: KOSPI200 지수의 종가와 개별 기업의 거래량
- 주요 변수: 거래량(Trading)과 변동률(Change)을 주요 거래 특성으로 선정

https://kr.investing.com/

2022-04-05	10	0	0.1612903226	Tuesday	0
2022-04-06	8	0	0.1290322581	Wednesday	0
2022-04-07	3	0	0.04838709677	Thursday	0
2022-04-08	3.333333333	0	0.05376344086	FridaySaturdaySund	0
2022-04-11	6	0	0.09677419355	Monday	0
2022-04-12	10	0	0.1612903226	Tuesday	0
2022-04-13	11	0	0.1774193548	Wednesday	0
2022-04-14	2	0	0.03225806452	Thursday	0
2022-04-15	2.666666667	0	0.04301075269	FridaySaturdaySund	0
2022-04-18	4	0	0.06451612903	Monday	0
2022-04-19	6	0	0.09677419355	Tuesday	0
2022-04-20	7	0	0.1129032258	Wednesday	0
2022-04-21	9	0	0.1451612903	Thursday	0
2022-04-22	19	0	0.3064516129	FridaySaturdaySund	0
2022-04-25	26	0	0.4193548387	Monday	0
2022-04-26	7	0	0.1129032258	Tuesday	0
2022-04-27	5	0	0.08064516129	Wednesday	0
2022-04-28	6	0	0.09677419355	Thursday	0
2022-04-29	0.6666666667	0	0.01075268817	FridaySaturdaySund	0

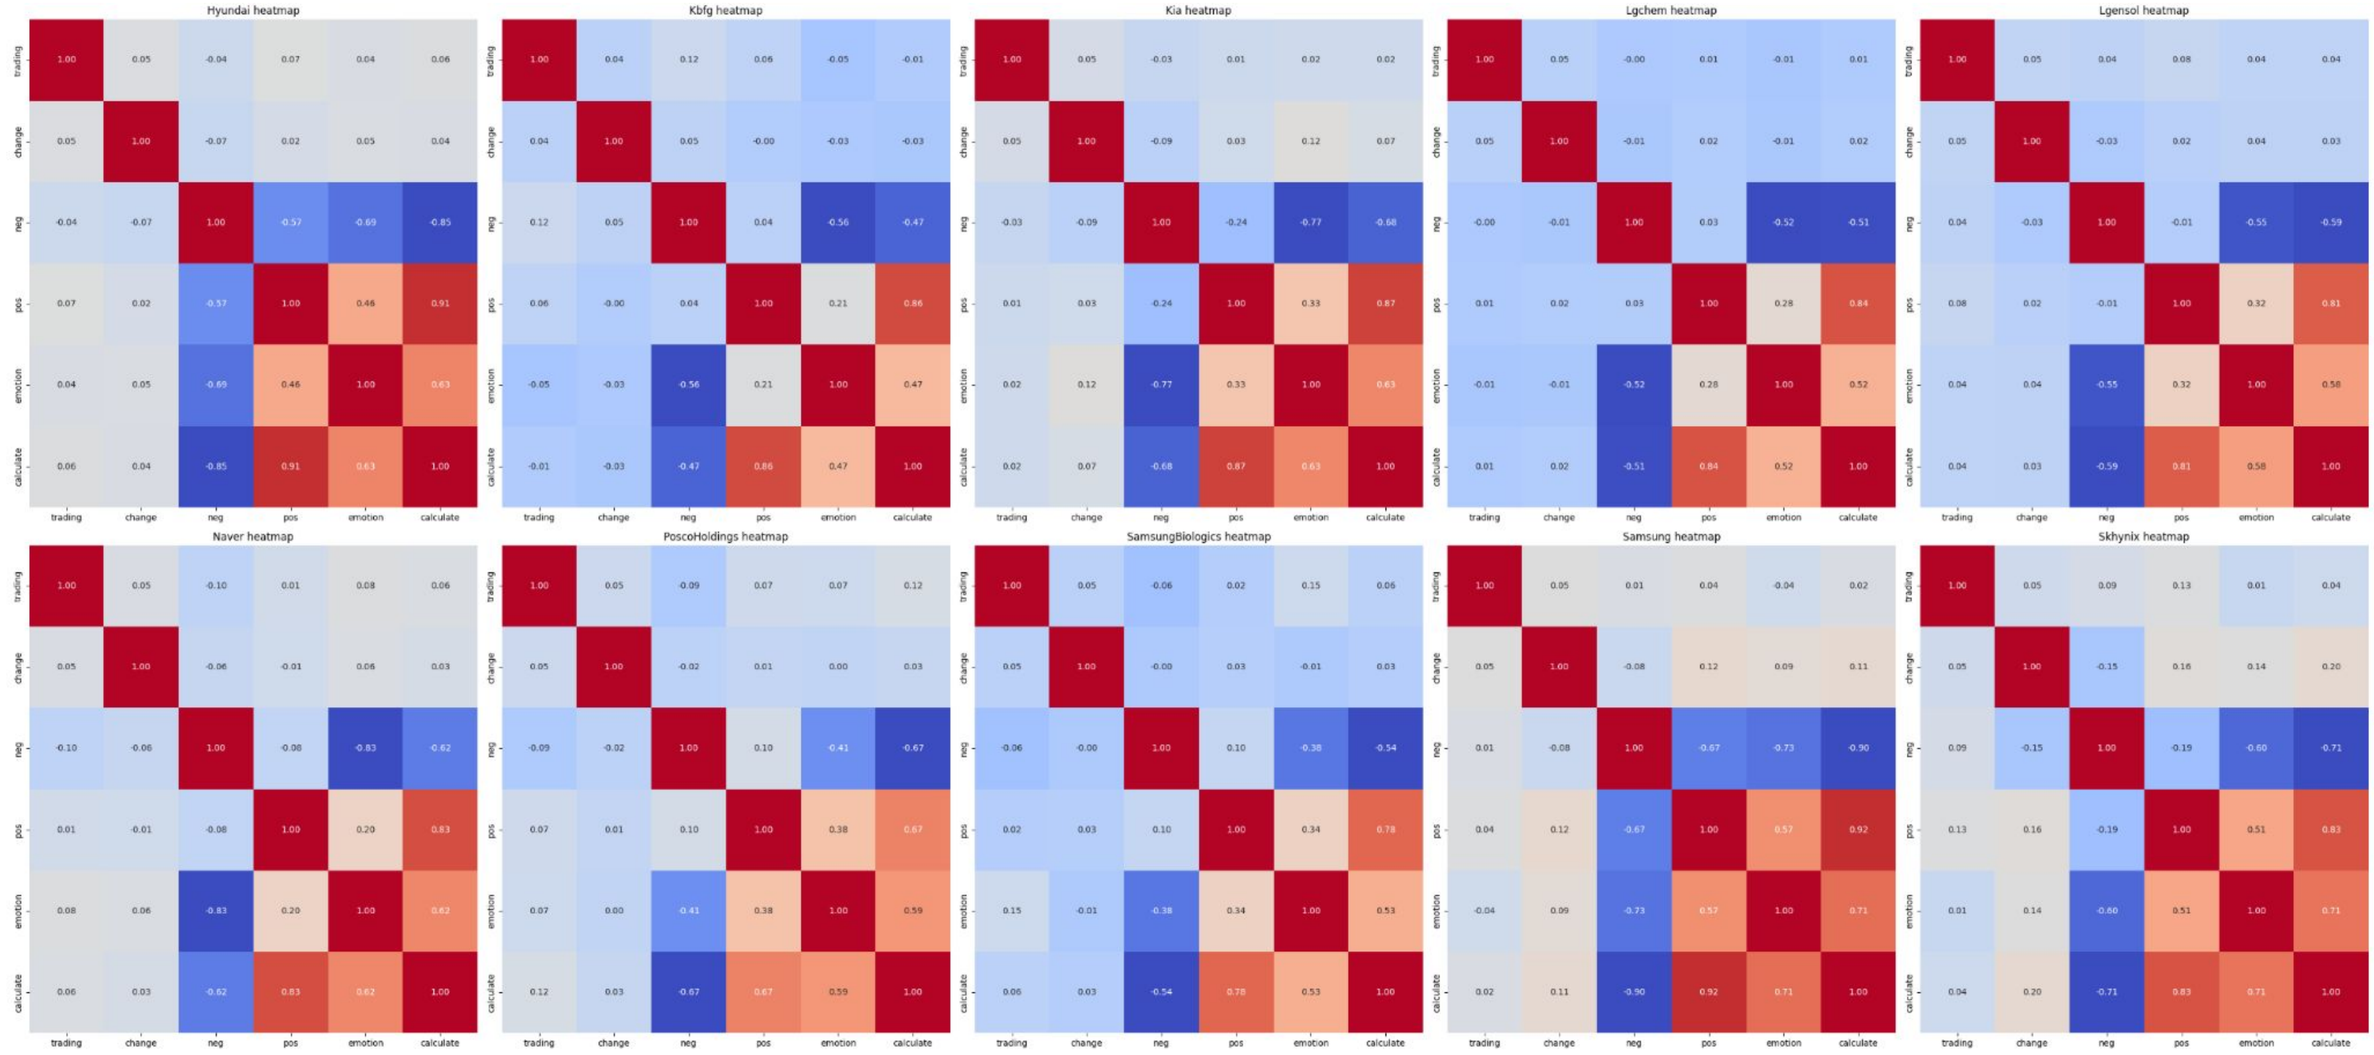
데이터 전처리 및 통합

- 결측치 처리: 휴일과 주말의 결측치는 가장 최근 영업일 데이터로 대체
- 정규화: MinMaxScaler를 활용하여 모든 입력 변수를 0~1 범위로 정규화
- 변동성 계산: 단순 일간 수익률 변동을 기준으로 계산
- 데이터 통합: 거래일 기준으로 정렬 후 inner join 방식으로 뉴스 데이터와 통합

데이터 전처리 및 분석 과정 (1)

기업별 특성 분석	데이터 정규화 및 스케일링	시계열 입력 구성 및 분할
- 총 6개 피처 생성 및 분석 - pos: 긍정 감성 확률 - neg: 부정 감성 확률 - emotion: 감성 지표 - calculate: 순감성(긍정-부정) - trading: 거래량 - change: 변동률(일간 수익률) - 상위 10개 기업에 적용하여 총 60차원 입력 벡터 구성	- MinMaxScaler 적용 - 모든 입력 변수를 0~1 범위로 정규화 - 데이터 누설 방지를 위한 처리 - Train 데이터에만 스케일러 적합 - Validation 및 Test 구간에는 동일 변환 적용 - 예측 후 역정규화(inverse_transform) 수행 - 실제 가격 수준으로 해석 가능하도록 처리	- 21일 이동 윈도우 기반 시계열 샘플 구성 - 목표값(y): KOSPI200 지수의 다음 거래일 종가 - 데이터 분할 비율 - Train: 71% - Validation: 15.1% - Test: 13.9% - 시계열의 시간적 순서 엄격히 보존 - 각 구간 시간 순서대로 분리

데이터 전처리 및 분석 과정 (2)



https://www.bigkinds.or.kr/

모델 학습 및 최적화

지수 예측을 위한 최적화 알고리즘으로 Adam optimizer를 선택
Adam은 적응적 학습률과 모멘텀 조정이 결합된 최적화 기법

- Adam optimizer는 적응적 학습률과 모멘텀 조정을 결합한 최적화 알고리즘으로, 학습 과정에서 파라미터별 학습률을 동적으로 조정.

- 초기 실험에서는 SGD, RMSProp, Adagrad 등 다양한 최적화 알고리즘을 시도했으나, 학습 속도 저하와 수렴 불안정성으로 인해 예측 성능이 크게 저하됨.

- Adam은 1차 모멘트(평균)와 2차 모멘트(분산)를 모두 활용하여 Gradient의 방향과 크기를 조정함으로써, 학습 초기에는 빠른 수렴을, 후기에는 안정적인 최적화를 가능하게 제작.

- 특히 변동성이 높은 금융 시계열 데이터에서도 Adam은 안정적으로 수렴하며, 일관되고 우수한 예측 지표를 나타내었음음.

- 학습률 0.001, 베타1 0.9, 베타2 0.999, 엡실론 1e-8의 기본 하이퍼파라미터 설정으로 최적의 성능을 달성.

모델 구조 및 설계

입력층	은닉층	출력층
- 기업별 60차원 시계열 피처로 구성 - KOSPI200 상위 10개 기업의 6개 특성 (긍정, 부정, 감성, 순감성, 거래량, 변동률) - 각 기업당 6개 특성 × 10개 기업 = 60차원 - 21일 이동 윈도우 기반 시퀀스 입력 - MinMaxScaler를 통한 0~1 범위 정규화 - 시간적 순서를 보존한 데이터 분할	- LSTM 또는 GRU 은닉 유닛 50개 - 2개 층으로 구성된 심층 구조 - 장기 의존성 문제 해결을 위한 게이트 메커니즘 - LSTM: 입력, 망각, 출력 게이트로 구성 - GRU: 업데이트, 리셋 게이트로 구성 - Dropout 적용으로 과적합 방지 - 시계열 패턴 학습에 최적화된 구조	- KOSPI200 지수의 다음 거래일(T+1) 종가 예측 - 단일 노드의 회귀 출력 구조 - 손실 함수: 평균제곱오차(MSE) 사용 - Adam Optimizer(학습률=0.001) 적용 - Scaler.inverse_transform을 통한 역정규화 - 실제 가격 수준으로 해석 가능한 출력값 생성

모델 학습 세부 사항

- 본 연구에서는 KOSPI200 지수 예측을 위해 과거 21일 데이터를 입력 시퀀스로 활용하여 다음 1일의 종가 수준을 예측하는 방식으로 모델을 구현함.
- 학습은 에포크 100회, 배치 크기 64로 진행했으며, Early Stopping 기법을 도입하여 검증 성능이 더 이상 개선되지 않는 시점에서 학습을 중단함으로써 과적합을 방지.
- 학습 과정에서 검증 손실이 가장 낮은 모델 가중치를 저장하여 최종 예측에 활용하는 모델 체크포인트 기법을 적용했다.

- 모델 학습 과정에서는 데이터의 시간적 순서를 엄격히 보존하면서 Train 71%, Validation 15.1%, Test 13.9%로 분할.
- 미래 정보가 과거 예측에 활용되는 데이터 누수를 방지하기 위함.
- 정규화 과정에서도 Train 데이터에만 스케일러를 적합시키고, 동일한 변환을 Validation 및 Test 구간에 적용하여 일관성을 유지.
- 학습 안정성을 위해 기울기 클리핑(Gradient Clipping)을 적용하였으며, 학습률 감소(Learning Rate Decay) 전략을 통해 수렴 속도와 정확도의 균형을 맞춤춤.

모델 평가 지표

평균 절대 오차(MAE)

$$\mathrm{MAE} = \frac{1}{m}\sum_{i=1}^{m}|X_i - Y_i|$$

- 예측값과 실제값 간 오차의 절대값 평균
- 단위가 원본 데이터와 동일하여 해석 용이
- 이상치에 상대적으로 덜 민감한 특성

Wang, W., & Lu, Y. (2018). An analysis of the performance of mean absolute error and root mean square error in predicting daily average global horizontal irradiance. Journal of Applied Meteorology and Climatology, 57(1), 167-182.

평균 제곱근 오차(RMSE)

$$\mathrm{RMSE} = \sqrt{\frac{1}{m}\sum_{i=1}^{m}(X_i - Y_i)^2}$$

- 예측값과 실제값 차이의 제곱근 평균
- 큰 오차에 더 큰 페널티 부여
- MAE보다 이상치에 민감한 특성

Willmott, C. J., & Matsuura, K. (2005). The use of the mean absolute error (MAE) in an assessment of the predictive accuracy of a global climate model. Climatic Change, 72(1), 21-36.

평균 절대 백분율 오차(MAPE)

$$\mathrm{MAPE} = \frac{1}{m}\sum_{i=1}^{m}\left|\frac{Y_i - X_i}{Y_i}\right|$$

- 실제값 대비 오차의 상대적 크기 측정
- 데이터 규모와 무관하게 모델 성능 비교 가능
- 백분율(%) 단위로 직관적 해석 가능

Bock, T. et al. (2018). Understanding the limitations of the mean absolute percentage error (MAPE) as a measure of forecast accuracy. International Journal of Forecasting, 34(3), 517-531.

결정계수(R^2) 및 F1 점수

$$\mathrm{R}^2 = 1 - \frac{\sum_{i=1}^{m}(X_i - Y_i)^2}{\sum_{i=1}^{m}(\bar{Y} - Y_i)^2}$$

- R^2: 모델이 설명하는 분산의 비율
- 1에 가까울수록 설명력이 높음

$$F1 = \frac{2\,TP}{2\,TP + FP + FN}$$

- F1 점수: 정밀도와 재현율의 조화평균으로 방향성 예측 성능 평가

Dynamic UNet, Unet model using PixelShuffle ICNR upsampling that can be built on top of any preTrained architecture, https://docs.fast.ai/vision.models.unet.html (November 1, 2024).

Young, P. H. (2000). The coefficient of determination (R-squared) is more powerful than is often believed. A. W. W. A. Journal, 92(1), 162-167.

탐색적 데이터 분석 결과

1. 종가 데이터만 사용한 기본 모델

- 종가 데이터만으로 예측 시도
- RMSE: 15.4074
- MAE: 11.3164
- R^2: -0.0125 (예측 불가능)
- 단일 변수로는 복잡한 시장 패턴 포착 실패

2. 감성 분석 데이터 추가 모델

- KoBERT 기반 감성 분석 결과(긍정/부정) 추가
- RMSE: 12.1246 (21.3% 감소)
- MAE: 10.0023 (11.7% 감소)
- R^2: 0.3730 (설명력 대폭 향상)
- 순 감성 점수(pos-neg) 추가 시 성능 추가 개선
  (RMSE: 11.0593, R^2: 0.4783)

3. 하이퍼파라미터 및 기업 비율 최적화

- 하이퍼파라미터 최적화 및 기업별 KOSPI200 비율 반영
- RMSE: 10.0694 (8.9% 추가 감소)
- MAE: 8.0649 (12.2% 추가 감소)
- R^2: 0.4999 (0.5에 근접)
- 기업 시가총액 비중 반영이 예측 정확도 향상에 기여

4. 거래 특성 및 앙상블 모델 적용

- 거래량, 변동성 특성 및 앙상블 기법 적용
- RMSE: 7.4357 (26.2% 대폭 감소)
- MAE: 6.1045 (24.3% 대폭 감소)
- R^2: 0.7286 (설명력 크게 향상)
- 거래량-주가 간 양의 상관관계 확인
- 주가 방향성 예측 정확도: 60.2%

모델 학습 및 평가 조건 [총 3,584개]

모델 구조

- LSTM: Units [100,50,25], Dropout [0.3,0.15,0.1]
- CNN: Units [50,50,50], Dropout [0.25,0.19,0.1]
- GRU: Units [100,50,25], Dropout [0.3,0.15,0.1]
- 앙상블 조합: LSTM, CNN, GRU, LSTM+CNN, LSTM+GRU, GRU+CNN, LSTM+CNN+GRU

데이터 케이스

- Case A: 종가 + 긍정/부정 감성
- Case B: 종가 + 긍정/부정 감성 + 거래량
- Case C: 종가 + 긍정/부정 감성 + 변동성
- Case D: 종가 + 긍정/부정 감성 + 거래량 + 변동성

기업 비율 및 스케일러

- Cap_on: 기업별 KOSPI200 차지 비율 포함
- Cap_off: 기업별 KOSPI200 차지 비율 비포함
- MinmaxScaler: 0~1 범위 정규화
- StandardScaler: 평균 0, 표준편차 1로 정규화

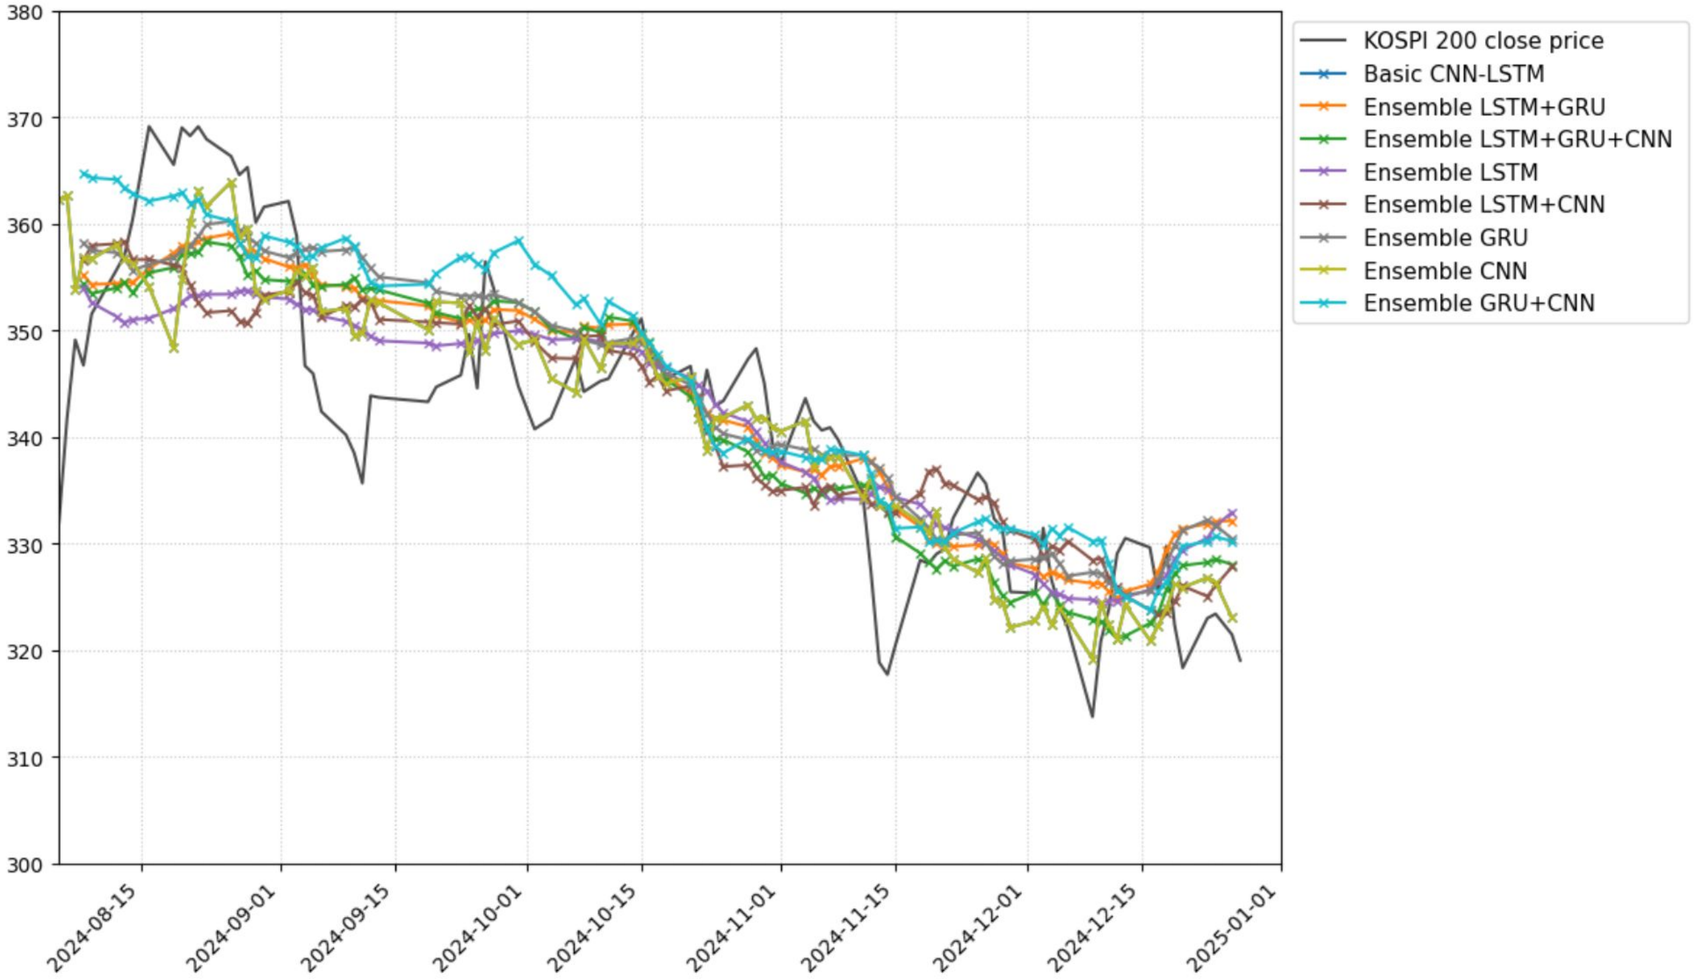
학습 파라미터

- Time_step: 20일 또는 21일 이동 윈도우
- Train_ratio: 0.7 또는 0.71
- Val_ratio: 0.15 또는 0.151
- 평가지표: RMSE, MAE, R^2, MAPE, F1 Score

앙상블 모델 학습 및 평가 (1)

Seed Ensemble	Hybrid Ensemble	앙상블 조합 및 통합 방식
- 동일 모델 구조(LSTM)를 서로 다른 초기 시드로 학습 - 5회 반복 학습을 통한 모델 구성 - 예측 결과를 평균화(소프트 보팅)하는 기법 - 초기 파라미터 설정 차이로 인한 결과 변동성 감소 - 단일 모델 대비 분산 감소 효과 - 일반화 성능 개선 및 안정적 예측 가능 - 학습 시간은 증가하나 예측 정확도 향상 - 과적합 위험 감소	- 서로 다른 모델 구조의 결과를 통합하는 방식 - LSTM과 GRU의 장점을 결합한 구조 - 장기 의존성과 단기 패턴을 동시에 포착 - 단일 모델 대비 예측 오차 감소 - 변동성이 큰 금융 시계열에 적합 - 모델 간 상호 보완적 학습 효과 - 다양한 시장 상황에 대한 적응력 향상 - 복잡한 비선형 패턴 포착 능력 강화	- 총 7가지 앙상블 조합 실험 (LSTM, CNN, GRU, LSTM+CNN, LSTM+GRU, GRU+CNN, LSTM+CNN+GRU) - 평균 기반 소프트 보팅 방식 적용 - 각 모델의 예측값을 동일 가중치로 평균화 - 단순하면서도 안정적인 성능 확보 - 스태킹이나 가중 투표 방식 대비 구현 용이 - 모델 간 상관관계가 낮을수록 효과적 - 다양한 관점의 예측 결과 통합

앙상블 모델 학습 및 평가 (2)



최적 모델 성능 비교

Model: LSTM+GRU, Units:[100,50,25]

Dropout [0.3,0.15,0.1]

Case C(감성+변동성)

Cap_on

MinMax

time_step = 20

train_ratio : 0.71

val_ratio : 0.151

LSTM+GRU 모델 성능

- RMSE: 7.564, MAE: 6.065, R^2: 0.712
- MAPE: 0.0178, F1 Score: 0.608
- Case C(감성+변동성) 입력 조건 적용
- Cap_on 방식과 MinMax 정규화 적용 시 최적 성능 도출

Model: LSTM+GRU+CNN, Units:[100,50,25]

Dropout [0.3,0.15,0.1]

Case C(감성+변동성)

Cap_on

MinMax

time_step = 20

train_ratio : 0.71

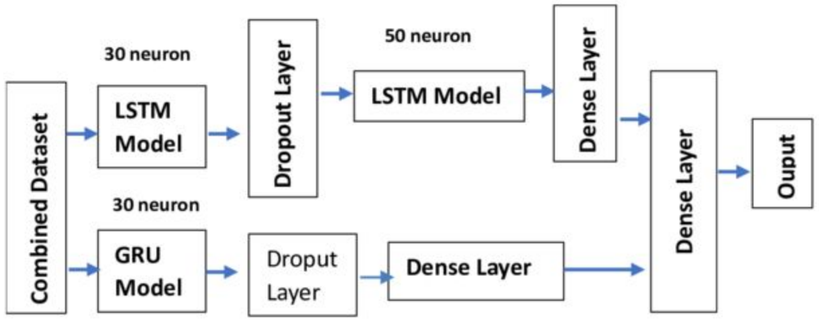
val_ratio : 0.151

LSTM+GRU+CNN 모델 성능

- RMSE: 7.573, MAE: 6.262, R^2: 0.711
- MAPE: 0.0183, F1 Score: 0.541
- 단일 모델 대비 예측 오차 감소
- LSTM+GRU와 유사한 회귀 성능 보유

방향성 예측 성능 분석

LSTM + GRU

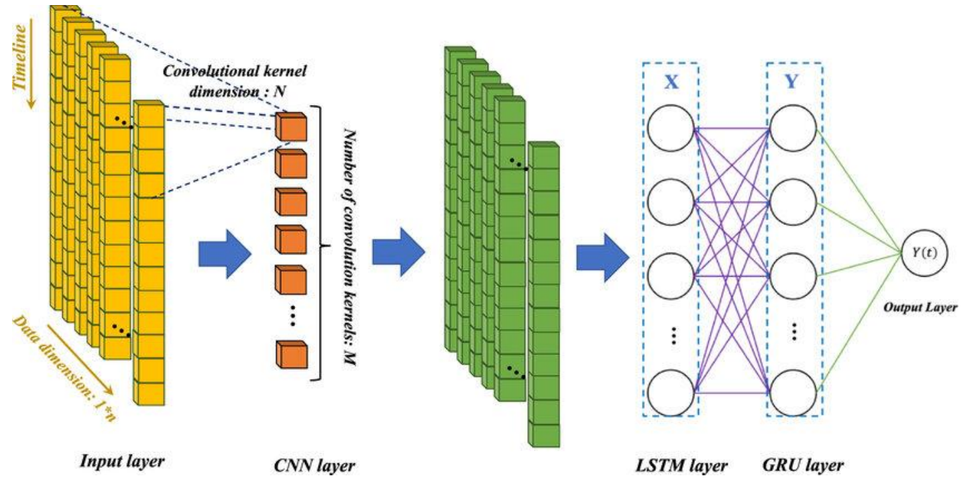


회귀 모델의 방향성 예측 한계

- LSTM+GRU와 LSTM+GRU+CNN: 회귀 지표에서 우수한 성과
- 상승(Up) 클래스에 대한 재현율(Recall)이 낮은 문제 발견
- 미세한 등락을 강제로 상승/하락으로 구분하는 과정에서 오분류 발생

https://www.researchgate.net/figure/Hybrid-LSTM-GRU-Prediction-Model-Architecture_fig2_374711738

LSTM + GRU + CNN



모델별 방향성 예측 성능 비교

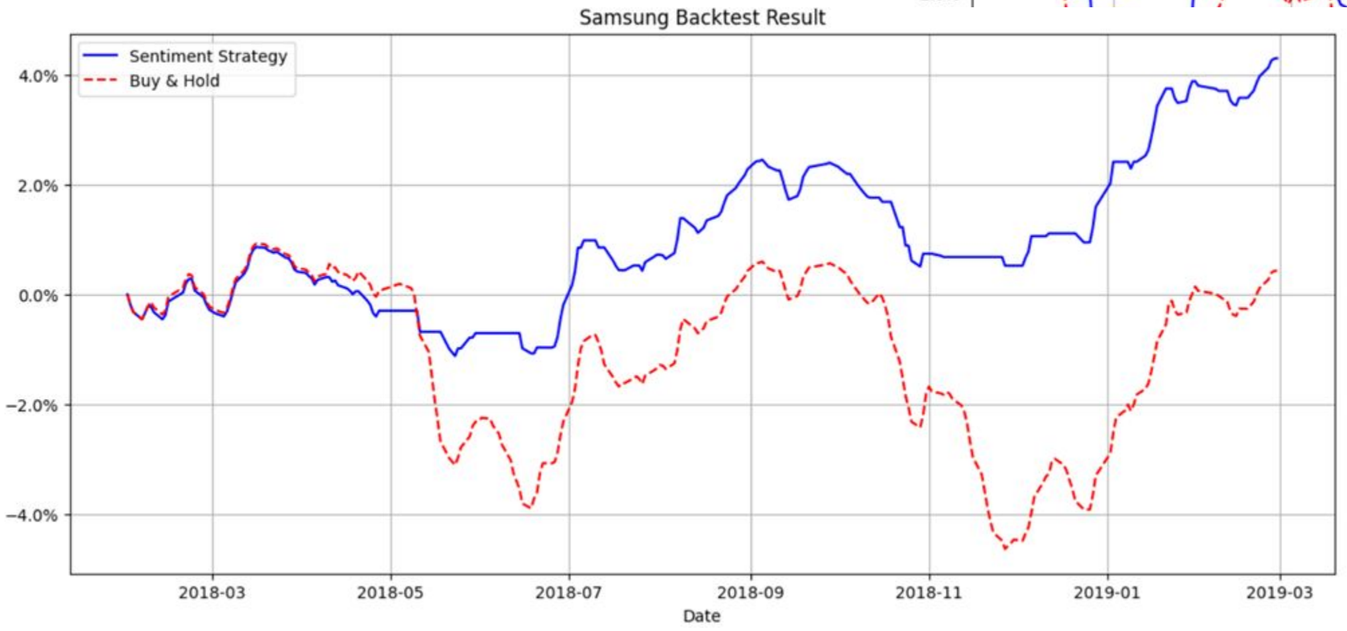
- CNN과 GRU+CNN: 단기 패턴 학습 능력으로 방향성 분류 정확도 높음
- 회귀 성능은 LSTM+GRU보다 낮으나 방향성 예측에서 강점
- 향후 보합 구간을 별도 클래스로 확장 필요성 제시
- 환율, 금리, 해외 지수 등 외부 거시 변수 추가 고려

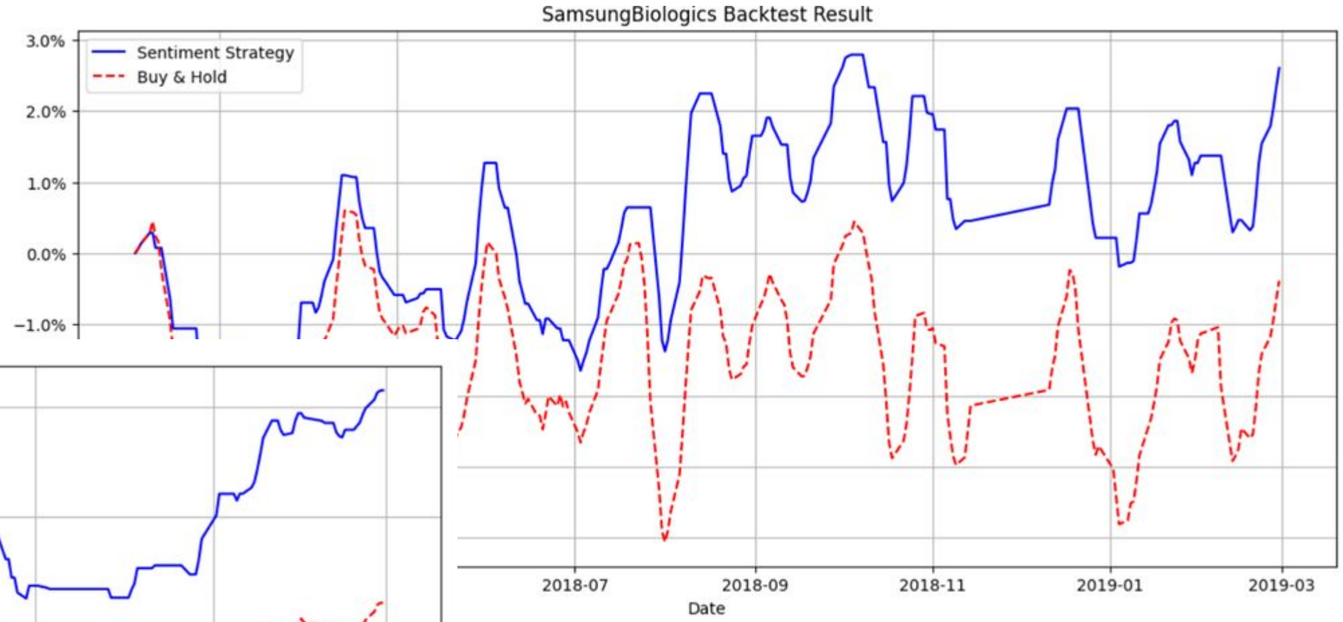
https://www.researchgate.net/figure/CNN-LSTM-GRU-position-predictive-model-structure_fig5_382527452

Backtesting 결과 (1)

투자 전략 설계	기업별 수익률 분석	업종별 성과 차이
- 감성 분석 기반 투자 전략의 실효성 검증 - 전략 규칙: · 긍정 감성(1) 발생 시 매수 · 부정 감성(0) 발생 시 매도 - 초기자본: 1천만 원 설정 - 모델 예측값(y_pred) 기준 자본 변화 추적 - 비교대상: Buy & Hold 전략 - 단순 전략으로 세금, 수수료 등 현실적 제약 미반영	- 삼성전자: +4.31% (Buy & Hold: +2.7%) - 삼성바이오로직스: +2.60% (Buy & Hold: +1.8%) - 네이버: +1.83% (Buy & Hold: +1.5%) - 감성 분석 신호가 실제 주가 흐름과 일정 부분 부합 - 대형 IT 기업에서 상대적으로 높은 예측 정확도 - 시장 변동성이 큰 구간에서도 안정적 성과 - 감성 요인이 주가 예측에 기여함을 실증	- IT, 바이오, 플랫폼: 감성 기반 전략 효과적 - 금융업종(KB금융: -13.56%): 전략 성과 부진 - 뉴스 감성이 주가에 직접 반영되지 않는 업종 존재 - 감성 분석 기반 투자 전략은 기업 및 업종에 따라 효과 상이 - 특정 산업군에 대한 선별적 적용 필요 - 업종별 특성을 반영한 차별화된 전략 설계 필요 - 감성 지표의 업종별 가중치 조정 고려

Backtesting 결과 (2)





연구 결론

감성과 거래 특성의 융합 효과

- 뉴스 감성만 사용했을 때보다 감성과 거래 특성(거래량·등락률)을 결합했을 때 성능 향상이 뚜렷함
- 감성 데이터만 사용 시 단기적 이벤트에 과민하게 반응하는 경향 발견
- 거래 특성 반영 시 시장 참여자의 실제 매매 활동이 내재화되어 노이즈 감소
- 기존 연구들의 감성 의존적 접근 한계를 넘어선 융합형 접근의 유효성 입증

이원 가중 집계 방식의 유효성

- 방송사와 경제지의 3:1 이원 가중 집계 방식을 통해 국내 언론 생태계의 특수성 반영
- 매체 영향력 차이를 고려한 감성 집계의 중요성 확인
- 기존 해외 중심 연구와의 차별점으로 작용
- 국내 시장 환경에 최적화된 감성 지표 설계 가능성 제시

Hybrid Ensemble의 안정성

- 변동성이 큰 금융 데이터에서도 안정적 성능 확보
- 단일 모델 대비 예측 오차 감소 및 일반화 성능 향상
- 다양한 시장 상황에 대한 적응력 강화
- 모델 간 상호 보완적 학습을 통한 예측 안정성 제고

LSTM+GRU의 우수한 예측 성능

- RMSE 7.564, MAE 6.065, R^2 0.712로 최고 성능 기록
- 장기 추세(LSTM)와 단기 변동성(GRU)을 동시에 포착하는 구조적 강점
- 단일 모델 및 다른 앙상블 조합 대비 우수한 예측 정확도
- KOSPI200 T+1 종가 예측에 가장 효과적인 모델로 입증

연구의 한계 및 향후 연구 방향

- 본 연구는 한국어 뉴스 감성과 거래 특성을 결합한 KOSPI200 예측 모델을제안하였으나, 다음과 같은 한계점을 가진다.

- 데이터 구간이 3년(2022-2024)으로 한정되어 장기적 경제 사이클과 패턴을 충분히 반영하기 어려움

- KoBERT 기반 감성 분석 모델의 금융 도메인 적합성이 제한적이며, 미세한 뉘앙스 포착에 한계 존재

- 거래 특성으로 거래량·등락률만 포함하고 금리·환율·글로벌 지표 등 외생 변수는 배제됨

– 긍정 부정 말고도 무의미한 중간지점에 대한 값도 추가해서 진행해볼 예정

향후 연구에서는 금융·거시 지표를 포함한 확장형 입력 구조, Transformer 계열 모델과의 비교, 강화학습 기반 투자전략 시뮬레이션으로 발전시킬 필요가 있다. 또한 GPU 제약으로 인해 실행하지 못했던 batch size 조정 등 학습 최적화와 금리, 금값 등 추가 변수를 고려한 연구를 진행할 예정